



Proyecto de Grado
IA al Servicio de las Comunidades: Modelo de Clasificación
Automática de Plantas Cultivadas en Ecosistemas de Agricultura
Urbana

María Fernanda Izquierdo Aparicio
Ana María Ochoa Muñoz

Directores del Proyecto de Grado:
Néstor Armando Nova Arévalo, PhD
Juan Erasmo Gómez Morantes, PhD

Coordinadores de Proyecto de Grado:
Juan Pablo Pájaro Hernández
Katherine Cabrera Rodríguez

Pontificia Universidad Javeriana
Facultad de Ingeniería
Maestría en Analítica para la Inteligencia de Negocios

Primera Entrega
Febrero 24 de 2025, Bogotá D.C.

Tabla de contenido

1. Introducción.....	3
2. Relación Estratégica	4
Justificación y Generación de Valor para la Universidad y Comunidad	4
Contexto de la Agricultura Urbana en Bogotá	5
3. Objetivos.....	6
Objetivo General	6
Objetivos Específicos.....	6
4. Tarea Analítica.....	7
Pregunta Analítica.....	7
Justificación de la Tarea Analítica	7
Tarea de Aprendizaje Automático y Enfoque	8
Impacto y Aplicabilidad	8
5. Flujo de Datos	8
Estado del Arte	10
6. Métricas de Evaluación	13
7. Referencias	14

Tabla de ilustraciones

Ilustración 1 Flujo de Datos	10
------------------------------------	----

1. Introducción

El presente documento detalla el desarrollo de una prueba de concepto de un modelo de inteligencia artificial destinado a la clasificación automática de imágenes de plantas cultivadas en huertos urbanos de las localidades de Usme y Rafael Uribe Uribe en Bogotá, Colombia. Este proyecto, que se desarrolla dentro de la postulación de la Pontificia Universidad Javeriana a la Alianza CAOBA¹, apoya desde la parte técnica la iniciativa *“Framework para la gestión del conocimiento comunitario sobre residuos sólidos orgánicos, respaldada por tecnologías 4.0”* de la Universidad Javeriana, cuyo despliegue cuenta con la aplicación móvil “Residuos Conciencia”, la cual será la herramienta para desplegar la prueba de concepto.

El objetivo principal de este proyecto de grado es diseñar y evaluar una solución basada en un modelo de redes neuronales convolucionales que permita identificar especies de plantas a partir de imágenes, alcanzando una precisión entre el 70% y el 85% en un plazo de cuatro meses. Para lograr esto, el modelo se entrenará utilizando imágenes de fuentes abiertas y de las imágenes recolectadas en la app “Residuos Conciencia”, a la vez que se integrará en la aplicación con el fin de desarrollar un módulo dentro de la misma que le permite a los usuarios identificar plantas que tengan en sus huertos urbanos.

Para el desarrollo del proyecto, el proceso comienza con la recolección de imágenes de plantas, las cuales pueden ser capturadas por los usuarios de la app y almacenadas en un repositorio de AWS, o ser extraídas de bases de datos abiertas. Estas imágenes se almacenan en la nube y son sometidas a procesos de limpieza y etiquetado. Posteriormente, el modelo de inteligencia artificial se entrena con estas imágenes y se ajusta para mejorar su precisión. Finalmente, se integra el modelo en la aplicación, permitiendo que los agricultores carguen imágenes de sus plantas y reciban información automática sobre su clasificación.

Este proyecto tiene como meta cerrar brechas digitales y fortalecer la gestión del conocimiento agrícola en comunidades urbanas que hacen parte de la iniciativa liderada por la Universidad Javeriana. Dentro del marco del proyecto, la coordinación del conocimiento y la aplicación de tecnologías emergentes se presentan como mecanismos clave para superar las brechas de información, fomentar la apropiación del conocimiento y facilitar la adopción de buenas prácticas en agricultura urbana. Al ofrecer una herramienta accesible, los agricultores podrán identificar sus cultivos con mayor facilidad, optimizar el manejo de sus huertas y prevenir enfermedades en sus plantas. De esta forma el proyecto no solo impulsa el uso de la inteligencia artificial en la agricultura urbana, sino que también contribuye a la apropiación del conocimiento y al desarrollo comunitario.

¹ Centro de Excelencia y Apropiación en Big Data y Data Analytics

2. Relación Estratégica

Justificación y Generación de Valor para la Universidad y Comunidad

El presente proyecto se alinea con los objetivos estratégicos de la Pontificia Universidad Javeriana, particularmente en su misión de servicio a la sociedad y su compromiso con la innovación y el desarrollo tecnológico con impacto social. A través del desarrollo de un modelo de clasificación automática de imágenes de plantas, embebido en la aplicación *Residuos Conciencia*, se generan beneficios tanto para la comunidad como para la universidad.

Para la comunidad, esta iniciativa permite fortalecer el conocimiento sobre agricultura urbana mediante herramientas accesibles basadas en inteligencia artificial, facilitando la identificación de especies y la apropiación de buenas prácticas agrícolas. De esta manera, se empodera a las comunidades locales, mejorando su acceso a la información ambiental y contribuyendo a su calidad de vida. Además, la implementación de tecnologías emergentes se presenta como una oportunidad clave para reducir la brecha digital y social, facilitando la apropiación del conocimiento y el uso de herramientas tecnológicas en comunidades marginadas.

Para la universidad, este proyecto refuerza su posicionamiento como líder en investigación aplicada en inteligencia artificial y análisis de datos. A través de su participación estratégica en la Alianza CAOBA, la Pontificia Universidad Javeriana fortalece su presencia en proyectos de big data y analítica avanzada, consolidando su papel en el desarrollo de soluciones innovadoras con impacto real.

En términos específicos, el proyecto contribuye directamente a:

- **Fortalecimiento del conocimiento comunitario:** Promueve la apropiación y compartición de conocimientos sobre agricultura urbana entre los miembros de la comunidad.
- **Cierre de la brecha digital:** Reduce la disparidad en el acceso y uso de herramientas tecnológicas al llevar inteligencia artificial a comunidades marginadas.
- **Apoyo a la sostenibilidad ambiental:** Facilita la gestión de residuos orgánicos y la agricultura urbana, promoviendo prácticas más sostenibles y contribuyendo a la seguridad alimentaria local.
- **Generación de datos valiosos:** La base de datos visual de imágenes de plantas, construida con el conocimiento de los agricultores, puede ser utilizada para investigación y desarrollo en agronomía urbana.
- **Mejora de la eficiencia agrícola:** La identificación automática de plantas permite a los huerteros urbanos tomar decisiones más informadas sobre el manejo de cultivos.

El proyecto se alinea con tendencias globales que impulsan la agricultura sostenible y el uso de tecnologías para el desarrollo comunitario (ONU, 2015). Además, la colaboración con la Fundación Skat y el Jardín Botánico de Bogotá asegura su sostenibilidad y escalabilidad, permitiendo que más comunidades puedan beneficiarse en el futuro.

Contexto de la Agricultura Urbana en Bogotá

La agricultura urbana en Bogotá, especialmente a través de huertos urbanos, ha emergido como una respuesta a diversas problemáticas sociales, económicas y ambientales. Este fenómeno se caracteriza por la producción de alimentos en espacios urbanos, lo que permite a los habitantes acceder a productos frescos y saludables, al tiempo que promueve la sostenibilidad y el fortalecimiento de la comunidad.

Definición y Relevancia

La agricultura urbana se refiere a las actividades agrícolas que se realizan dentro de las áreas urbanas, sin importar su tamaño o propósito. Según la FAO (Landon-Lane, 2005) estas prácticas pueden incluir desde pequeños huertos familiares hasta iniciativas comunitarias más grandes. En Bogotá, esta forma de agricultura ha cobrado especial relevancia como un medio para mejorar la seguridad alimentaria, especialmente en comunidades vulnerables que enfrentan condiciones de pobreza y desplazamiento forzado (Torres Vivas, 2018).

Beneficios Socioeconómicos

Los huertos urbanos no solo contribuyen a la alimentación de los hogares, sino que también generan beneficios económicos al permitir la venta de productos en mercados locales. Según Cantor Marín (2010) esta actividad es crucial para las poblaciones que han sufrido migraciones forzadas debido al conflicto armado en Colombia y que se han reubicado en zonas marginales de Bogotá, ya que les proporciona una fuente de ingresos y una forma de reintegrarse a la vida comunitaria.

Sostenibilidad Ambiental

Desde el punto de vista ambiental, los huertos urbanos ayudan a mitigar el impacto del crecimiento urbano desmedido al promover la conservación del espacio verde y la biodiversidad. Además, fomentan prácticas agrícolas sostenibles que pueden contribuir a la recuperación de suelos contaminados y a la gestión adecuada de residuos orgánicos (Betancourt, 2017).

Desafíos

A pesar de sus beneficios, la agricultura urbana en Bogotá enfrenta varios desafíos. La falta de apoyo institucional y recursos para los agricultores urbanos limita el potencial de estas iniciativas. Además, muchos huertos se sitúan en áreas con alta contaminación del suelo y del aire, lo que puede afectar la calidad de los productos cultivados (Cantor Marín, 2010).

Iniciativas Comunitarias

Existen diversas iniciativas comunitarias que buscan promover la agricultura urbana en Bogotá. Por ejemplo, organizaciones locales han implementado programas de capacitación sobre técnicas agrícolas sostenibles y han facilitado el acceso a insumos necesarios para el cultivo (Secretaría Distrital de Ambiente, 2022). Estas iniciativas son fundamentales para empoderar a las comunidades y fomentar un sentido de pertenencia y responsabilidad hacia el entorno urbano (Pantoja Bohórquez, Martínez Grisales, Rincón Vivas, & Boada Arias, 2024).

Políticas Públicas

Las políticas públicas también juegan un papel crucial en el desarrollo de la agricultura urbana en Bogotá. A través del Acuerdo 605 del 27 de agosto de 2015², se han establecido lineamientos para fomentar programas agroecológicos en áreas urbanas y periurbanas. Sin embargo, su implementación ha sido desigual y requiere un mayor compromiso por parte del gobierno local.

La agricultura urbana en Bogotá representa una estrategia valiosa para abordar problemas sociales y ambientales contemporáneos. A través de huertos urbanos, se pueden promover prácticas sostenibles que mejoren la calidad de vida de los habitantes, fortalezcan las economías locales y contribuyan a un entorno urbano más saludable. Sin embargo, es esencial superar los desafíos existentes mediante políticas efectivas y apoyo institucional para maximizar el impacto positivo de estas iniciativas en las comunidades bogotanas.

3. Objetivos

Objetivo General

Para el proyecto de *IA al Servicio de las Comunidades: Modelo de Clasificación Automática de Plantas Cultivadas en Ecosistemas de Agricultura Urbana* hemos definido que nuestro objetivo general sea el siguiente:

Desarrollar y validar una prueba de concepto de una solución basada en inteligencia artificial para la identificación y clasificación automática de plantas en huertas urbanas, mediante un modelo de clasificación de imágenes, logrando entre un 70% a un 85% de precisión en la identificación de especies, en un periodo de 4 meses.

Objetivos Específicos

Entendiendo el objetivo general, se proponen los siguientes objetivos específicos:

1. Recolectar, limpiar y preparar un conjunto de datos de imágenes de plantas comunes en huertas urbanas de las localidades de Usme y Rafael Uribe Uribe, asegurando que el 100% de las imágenes estén correctamente etiquetadas con información relevante (especie como primera etiqueta y, según disponibilidad de información, estado fenológico³ y posibles enfermedades) en un periodo de 2 meses.
2. Diseñar, entrenar y evaluar un modelo de clasificación de imágenes utilizando técnicas de aprendizaje automático bajo un modelo de redes neuronales convolucionales para identificar las especies de plantas presentes en las imágenes

² Formula los lineamientos para institucionalizar el programa de agricultura urbana y periurbana agroecológica de manera sostenible y de bajos costos para la ciudad.

³ El estado fenológico de una planta es el período en el que se desarrollan, transforman o desaparecen sus órganos. También se puede definir como el tiempo en que se manifiesta una característica biológica (<https://www.senamhi.gob.pe/load/file/01401SENA-11.pdf>)

alcanzando entre un 70% a un 85% de precisión en un conjunto de prueba durante un periodo de 4 meses.

3. Implementar y evaluar la solución en un entorno real con agricultores urbanos, midiendo su desempeño y usabilidad mediante encuestas de satisfacción (NPS), con el objetivo de recopilar retroalimentación para futuras mejoras, en un periodo de 1 mes.

Estos objetivos, que están formulado para ser claros (tienen una meta definida), medibles (se pueden evaluar los resultados del modelo y la satisfacción de los usuarios), alcanzables (se cuenta con los recursos y el conocimiento técnico necesario), han sido acordados con los directores del presente proyecto Néstor Armando Nova Arévalo, PhD y Juan Erasmo Gómez Morantes, PhD.

4. Tarea Analítica

La tarea analítica principal de este proyecto es la clasificación automática de imágenes de plantas en huertas urbanas, utilizando redes neuronales convolucionales (CNN). El objetivo es desarrollar un modelo de aprendizaje profundo capaz de identificar especies vegetales a partir de imágenes, asegurando un nivel de precisión entre 70% y 85% en su desempeño sobre un conjunto de prueba.

Pregunta Analítica

¿Cómo es posible identificar automáticamente la especie de una planta en una huerta urbana en Bogotá a partir de una imagen?

Justificación de la Tarea Analítica

El reconocimiento de especies vegetales mediante imágenes es un problema bien abordado en el campo de la visión por computadora y la inteligencia artificial. Sin embargo, los modelos existentes generalmente se entrenan con bases de datos de plantas en contextos controlados o con especies bien documentadas. En el caso de huertas urbanas en Bogotá, se presentan desafíos particulares:

1. **Variabilidad de las Imágenes:** Las fotos pueden tener diferencias en iluminación, ángulo de captura y fondo, lo que requiere que el modelo sea robusto ante estas variaciones.
2. **Diversidad de Especies:** Aunque existen especies comunes en huertas urbanas, la variabilidad en sus características morfológicas (hojas, tallos, flores) puede hacer que la clasificación sea compleja.
3. **Posibles Etiquetas Adicionales:** Dependiendo de la calidad de los datos recolectados, el modelo no solo identificará la especie, sino que podría incluir información sobre el estado fenológico y posibles enfermedades.

4. **Aplicación en un Entorno Real:** La solución no solo debe ser precisa en laboratorio, sino también efectiva en el uso por agricultores urbanos, lo que implica evaluar su usabilidad y adaptabilidad.

Tarea de Aprendizaje Automático y Enfoque

El problema a resolver es una tarea de clasificación supervisada de imágenes, donde cada imagen de planta debe ser asignada a una categoría correspondiente a su especie. Para esto:

- Se utilizarán redes neuronales convolucionales (CNNs), que han demostrado un alto desempeño en tareas de reconocimiento visual.
- Se entrenará el modelo con imágenes recolectadas en huertas urbanas de Bogotá y complementadas con datos de libre uso, asegurando que el conjunto de datos sea representativo.
- Se implementarán técnicas como data augmentation, regularización y ajuste de hiperparámetros para optimizar el rendimiento del modelo.
- Se evaluará el desempeño con métricas como precisión, recall y F1-score, garantizando que el modelo alcance el umbral de precisión esperado.

Impacto y Aplicabilidad

El desarrollo de esta solución permitirá a los agricultores urbanos y personas interesadas en la agroecología contar con una herramienta basada en inteligencia artificial para identificar especies vegetales de manera automática. Esto puede facilitar el manejo de cultivos, la prevención de enfermedades y la toma de decisiones en el cuidado de las huertas.

5. Flujo de Datos

El flujo de datos en el proyecto comienza con etapa de *Gestión de Datos*, que se trata de la recolección de imágenes de plantas en huertos urbanos, las cuales pueden provenir de distintas fuentes, como fotografías tomadas por los usuarios y guardadas en la base de datos de la app “Residuos Conciencia” y bases de datos especializadas y abiertas. Junto con estas imágenes, se recopilan metadatos relevantes, en principio se recopila su nombre y especie, y si se puede dependiendo de la información encontrada, recolectar el tipo de planta (si es una flor, árbol, aromática u hortaliza), su estado fenológico y si presenta algún tipo de enfermedad.

Una vez obtenidos los datos, estos se almacenan y organizan en una base de datos estructurada en el sistema de almacenamiento en la nube GitLab para este proyecto. La organización de la información se realiza con base en diferentes criterios, como el tipo de planta, el estado de crecimiento, la calidad de la imagen y su relevancia dentro del análisis. Esta estructuración permite un acceso más eficiente a los datos y facilita su posterior procesamiento.

El siguiente paso es el preprocesamiento y transformación de los datos. Aquí, primero se aplica una limpieza para eliminar imágenes de baja calidad o aquellas que no aporten información útil. Luego, se normalizan las imágenes ajustando su resolución, brillo y contraste para garantizar uniformidad en el conjunto de datos. Posteriormente, cada imagen se etiqueta de acuerdo con su contenido, clasificándola según las categorías de nombre (nombre común y nombre científico, tipo de planta, estado fenológico y si presenta algún tipo de enfermedad). Finalmente los datos son divididos en tres conjuntos (entrenamiento, validación y prueba) para poder entrenar y evaluar el modelo.

Una vez que los datos han sido procesados, se procede con la fase de *Aprendizaje del modelo* utilizando el set de entrenamiento creado en la fase anterior. Se utilizan modelos de aprendizaje automático, principalmente redes neuronales convolucionales (CNN)⁴, para analizar y clasificar las imágenes según las etiquetas asignadas. Durante el entrenamiento del modelo, se mide su desempeño utilizando métricas como precisión, recall y F1-score. Si los resultados no son óptimos, se ajustan los hiperparámetros para mejorar la capacidad de predicción del modelo.

Luego de haber realizado las dos primeras fases, y utilizado el set de validación, se entra a la fase de verificación del modelo, la cual es fundamental para garantizar que el sistema de clasificación de imágenes de plantas de huertos urbanos funcione de manera precisa y confiable antes de su implementación final. En esta etapa, se evalúa el desempeño del modelo con datos independientes (set de validación), se comprueba su capacidad de generalización y se aplican pruebas teóricas para validar su robustez.

El primer paso de esta fase consiste en la evaluación del modelo para generalizar, donde se verifica si las predicciones realizadas son consistentes en distintos escenarios y condiciones. Para esto, los requisitos del modelo se convierten en pruebas específicas y se analizan propiedades matemáticas que pueden ser verificadas formalmente. En otras palabras, se busca comprobar que el modelo no solo funcione bien con los datos con los que fue entrenado, sino que también tenga un buen rendimiento con imágenes nuevas y variadas.

Luego, se lleva a cabo la validación del modelo utilizando un conjunto de datos de prueba independiente mencionado anteriormente. En este proceso, se mide la capacidad de generalización del modelo evaluando su precisión en la clasificación de nuevas imágenes que no ha visto antes. Si el modelo muestra un alto desempeño en este conjunto de validación, se considera que tiene una buena capacidad predictiva y que no ha sufrido sobreajuste (overfitting) durante el entrenamiento.

Finalmente, se aplican pruebas teóricas mediante métodos matemáticos y métricas de evaluación rigurosas. Entre estas métricas se incluyen la precisión (accuracy), recall, F1-score y la matriz de confusión, que permiten analizar detalladamente el rendimiento del modelo en la clasificación de imágenes. Estos indicadores ayudan a identificar posibles errores

⁴ Revisar sección de [Estado del Arte](#) para entender las razones que conducen a la elección de este tipo de modelo.

sistemáticos, como falsos positivos o falsos negativos, y a ajustar el modelo para mejorar su desempeño.

Una vez superada la fase de verificación, el modelo es considerado apto para su despliegue e integración a la app “Residuos Conciencia”, el la cual el objetivo es que los usuarios pueden visualizar la información sobre plantas en sus huertos urbanos a partir de imágenes que cargan a la app y que son tratadas con el modelo desarrollado.

Este flujo de datos garantiza un procesamiento eficiente y estructurado, permitiendo la clasificación y análisis de imágenes de huertos urbanos de manera efectiva, con aplicaciones prácticas para la agricultura urbana y el cuidado de plantas en diversos entornos. A continuación se presenta una ilustración que resume el flujo de datos aquí descrito.




Ilustración 1 Flujo de Datos
Fuente: Elaboración Propia

Estado del Arte

A continuación se exploran las arquitecturas de modelos de aprendizaje profundo más utilizadas en esta tarea, incluyendo ResNet, Inception, Vision Transformers (ViT), EfficientNet y DenseNet, destacando sus fortalezas y aplicaciones en la clasificación de imágenes vegetales. Además, se analizan las métricas de rendimiento esenciales para evaluar estos modelos, como la precisión, la exhaustividad y el F1-score, enfatizando la importancia de la robustez y la capacidad de generalización en entornos urbanos con variaciones de iluminación, ángulos y fondos.

Asimismo, se abordan los requisitos de datos necesarios para entrenar modelos efectivos, incluyendo la importancia de contar con grandes y diversos conjuntos de datos, y el uso de técnicas de aumento de datos para mejorar la capacidad de generalización del modelo sin necesidad de recopilaciones adicionales.

Este análisis proporciona una visión integral del papel de los modelos de aprendizaje profundo en la clasificación de imágenes de plantas en la agricultura urbana, destacando cómo estos enfoques avanzados pueden contribuir a la automatización y optimización de los sistemas de identificación vegetal en entornos urbanos

Modelos de Aprendizaje Profundo para la Clasificación de Imágenes de Plantas en Agricultura Urbana

Para profundizar en la comprensión de los modelos de aprendizaje automático destinados a la clasificación de imágenes de plantas, particularmente en el contexto de la agricultura urbana, es esencial explorar diversas características, requisitos de datos e implementaciones de código.

Características de los Modelos de Aprendizaje Profundo

Resumen del estado del arte⁵

A continuación se describen el estado del arte por cada una de las referencias consultadas:

Referencia / Año	Modelo utilizado	Tipo de datos	Métricas de evaluación	Conclusiones
Pl@ntNet-300K: a plant image dataset with high label ambiguity and a long-tailed distribution	CNNs varias (ResNet, DenseNet)	300K imágenes de plantas con anotaciones inciertas.	Precisión, capacidad de generalización	Pl@ntNet-300K es útil para estudiar incertidumbre en clasificación de especies, pero muestra desempeño inferior a ImageNet debido a datos desbalanceados. Se entrenaron múltiples arquitecturas de redes neuronales (ResNet, EfficientNet, Vision Transformer, entre otras) con cross-entropy loss. Se encontraron grandes diferencias en el rendimiento dependiendo del número de imágenes por clase, con una precisión significativamente menor en especies poco representadas. Además, el desempeño en Pl@ntNet-300K es mucho más bajo que en ImageNet, lo que resalta la dificultad del dataset.
Detecting Flowers in Imagery for Grassland Biodiversity	Faster R-CNN	Imágenes de pastizales europeos (LUCAS 2018)	Precisión (0.89), Recall (0.61)	La visión por computadora puede automatizar y mejorar el monitoreo de biodiversidad en pastizales, pero requiere imágenes de mayor calidad y modelos más especializados. La integración de estas técnicas en programas como LUCAS podría acelerar la recolección de datos y mejorar la toma de decisiones en conservación.
Beyond Supervision: Self-Supervised Learning in Plant Disease Recognition	Vision Transformer (CL-ViT)	Imágenes de enfermedades en plantas (PlantVillage + dataset real)	Comparación con modelos previos (FF-ViT)	Aprendizaje auto-supervisado mejora la identificación de enfermedades nunca antes vistas (zero-shot learning). Este estudio establece un nuevo punto de referencia en la identificación de enfermedades en plantas sin ejemplos previos, destacando el potencial del aprendizaje auto-supervisado en aplicaciones agrícolas y sistemas de reconocimiento de imágenes.
PlantCLEF 2024	Vision Transformers (ViT, DinoV2)	1.7M imágenes de plantas individuales + 1,695 imágenes de parcelas	F1-score (28.73%)	Incorporar auto-supervisión (SSL) para mejorar el aprendizaje con imágenes no etiquetadas. Crear conjuntos de datos con imágenes de parcelas anotadas para reducir la diferencia entre entrenamiento y prueba. Explorar técnicas de segmentación multi-escala para adaptarse a diferentes tamaños de plantas en una imagen. Este estudio refuerza la importancia de adaptar modelos de visión por computadora a escenarios del mundo real, donde los datos no siempre coinciden con los de entrenamiento.
PlantCLEF 2022	CNNs + ViTs	4M imágenes de 80K especies	MA-MRR (0.626)	ViTs superaron a CNNs en identificación global de plantas, pero requieren más recursos computacionales. Aunque ruidosos, los datos extraídos de la web ayudaron a mejorar la generalización de los modelos. Optimizar modelos para manejar la gran cantidad de clases sin aumentar demasiado el costo computacional. Ampliar la cobertura de datos en regiones tropicales con menos representación en los datasets actuales. Este trabajo marca un avance en la identificación automática de plantas a gran escala, demostrando el potencial de Vision Transformers y aprendizaje auto-supervisado en la clasificación de biodiversidad.
LifeCLEF 2021	CNNs, ViTs	Imágenes de herbarios, audio de aves, datos satelitales	Precisión por tarea (PlantCLEF: 20% MRR, BirdCLEF: 0.6932 F1-score)	ViTs emergen como alternativa a CNNs en biodiversidad; se necesitan mejores técnicas de aprendizaje auto-supervisado.
AI-based Identification of Herbarium Specimens	CNNs con adaptación de dominio (GANs, métricas)	320K imágenes de herbarios + 3,186 fotos de campo	MRR (0.180 con regularización adversarial)	Las técnicas de aprendizaje profundo han mejorado significativamente la identificación de especies en imágenes, audio y datos ambientales. Los modelos Vision Transformers (ViTs) emergieron como una alternativa a las CNNs, aunque requieren más recursos computacionales. Los datos geográficos y de teledetección pueden mejorar la predicción de distribución de especies. Se identificaron desafíos en la identificación de especies en regiones tropicales, donde hay menos datos disponibles.
ML Using Digitized Herbarium Specimens for Phenology	Mask R-CNN	Imágenes de herbarios con anotaciones fenológicas	Precisión (96.3% en detección de estructuras)	El uso de ML en herbarios digitalizados facilita el análisis fenológico a gran escala, permitiendo un mejor monitoreo de la biodiversidad y los efectos del cambio climático. Aún quedan desafíos, como mejorar la calidad de los datos de entrenamiento y aplicar técnicas de aprendizaje auto-supervisado para optimizar la detección de patrones fenológicos.
Overview of LifeCLEF Plant Identification Task 2019: diving into Data Deficient Tropical Countries	Se probaron 26 modelos basados en CNNs, incluyendo Inception-ResNet, DenseNet y ResNet-50	Entrenamiento: 10,000 especies con 434,251 imágenes de la Enciclopedia de la Vida (EoL) y búsquedas web (Google, Bing). Prueba: 742 observaciones de campo identificadas por botánicos expertos.	El mejor modelo obtuvo 31.6% de precisión Top-1, muy por debajo del 67.5% logrado por expertos humanos. La diferencia del 36.5% en accuracy muestra que los modelos actuales aún no igualan la percepción humana en la identificación de especies tropicales	El estado del arte muestra que la identificación automática de plantas tropicales sigue siendo un reto abierto. A pesar de los avances en redes neuronales convolucionales y transformers, la falta de datos representativos y la alta biodiversidad dificultan la clasificación precisa. Se necesitan técnicas avanzadas para cerrar la brecha entre el rendimiento de modelos de deep learning y el de expertos botánicos
Clasificación de enfermedades en cultivos de papa empleando redes neuronales convolucionales Cristiano-Muñoz et al., 2023	VGG16, ResNet50, InceptionV4	760 imágenes de hojas de papa en campo, clasificadas en 5 categorías (enfermedades y sanas)	Precisión en prueba: ResNet50 (85.25%), InceptionV4 (99.67%)	La metodología de tres fases (transfer learning + mapas de calor) mejora significativamente la clasificación de enfermedades en cultivos de papa.

⁵ Esta información fue recopilada de artículos que se encuentran dentro de las Referencias.

Conclusiones

- **Tendencia hacia modelos más avanzados:** Vision Transformers (ViT) están superando a CNNs en algunas tareas, pero requieren mayor capacidad computacional.
- **Importancia del aprendizaje auto-supervisado (SSL):** Se menciona en varios estudios como una solución para mejorar la generalización y el rendimiento en especies no vistas.
- **Adaptación de dominio como reto clave:** Modelos entrenados en imágenes de laboratorio o herbarios tienen dificultades en entornos reales, por lo que es necesario mejorar la transferencia de conocimiento.
- **Mejoras en la detección de enfermedades:** Cristiano-Muñoz et al. (2023) muestra cómo el uso de mapas de calor mejora la detección en condiciones reales de campo.
- **Limitaciones en biodiversidad tropical:** Los modelos aún presentan grandes desafíos para clasificar especies en regiones con alta biodiversidad y escasez de datos.

Se define que la mejor alternativa para resolver la problemática planteada es CNN debido a que ha funcionado bastante bien en la identificación de imágenes de plantas y no requiere tanta capacidad computacional como otros modelos ni gran cantidad de datos.

6. Métricas de Evaluación

Para evaluar el desempeño del modelo de clasificación de imágenes, se utilizarán las siguientes métricas:

- **Precisión (precision):** Proporción de imágenes clasificadas como pertenecientes a una clase que realmente pertenecen a esa clase.
- **Exhaustividad (Recall):** Proporción de imágenes que pertenecen a una clase que son correctamente clasificadas como pertenecientes a esa clase.
- **F1-score:** Media armónica de la precisión y la exhaustividad, que proporciona una medida equilibrada del desempeño del modelo.
- **Exactitud (Accuracy):** Proporción de imágenes correctamente clasificadas sobre el total de imágenes.

Estas métricas están directamente relacionadas con la tarea analítica y los objetivos del proyecto, ya que permiten cuantificar la capacidad del modelo para identificar y clasificar correctamente las plantas en las imágenes.

Además, se recolectará retroalimentación cualitativa de los usuarios sobre la usabilidad y la utilidad de la aplicación móvil.

7. Referencias

- Betancourt Rada, B. A. (2016). *Bases Para La Reestructuración Del Programa De Agricultura Urbana Y Periurbana Agroecológica En Bogotá D.C., Con Base Los Lineamientos Dados En El Acuerdo 605 Del 27 De Agosto De 2015*.
<https://repository.udistrital.edu.co/server/api/core/bitstreams/deec61de-2c00-4e80-b85a-2c6f092bc2ca/content>
- Cantor Marín, K. M. (2010a). Agricultura urbana: elementos valorativos sobre su sostenibilidad. *Cuadernos De Desarrollo Rural*, 7(65), 61.
<https://doi.org/https://doi.org/10.11144/Javeriana.cdr7-65.auev>
- Cantor Marín, K. M. (2010b). *Agricultura urbana sostenibilidad y medios de vida experiencias en Ciudad Bolívar, Altos de Cazucá y Ciudadela Sucre*.
<https://doi.org/10.11144/JAVERIANA.10554.665>
- Chai, A. Y. H., Lee, S. H., Tay, F. S., Bonnet, P., & Joly, A. (2024). Beyond supervision: Harnessing self-supervised learning in unseen plant disease recognition. *Neurocomputing*, 610, 128608. <https://doi.org/10.1016/J.NEUCOM.2024.128608>
- Consejo de Bogotá. (2015). Acuerdo 605 de 2015 Concejo de Bogotá, D.C., (2015).
<https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=62903>
- Elvekjaer, N., Martinez-Sanchez, L., Bonnet, P., Joly, A., Paracchini, M. L., & van der Velde, M. (2024). Detecting flowers on imagery with computer vision to improve continental scale grassland biodiversity surveying. *Ecological Solutions and Evidence*, 5(2).
<https://doi.org/10.1002/2688-8319.12324>
- Garay Sarasti, H. (2019). Apropiación social por parte de grupos de interés para la conservación de los Cerros Orientales." *Secretaria Distrital de Ambiente*. www.ambientebogota.gov.co
- Garcin, C., Joly, A., Lombardo, J.-C., Affouard, A., Chouet, M., & Servajean, M. (2021). Pl@ntNet-300K: a plant image dataset with high label ambiguity and a long-tailed distribution. *Thirty-Fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*. <https://doi.org/https://doi.org/10.5281/zenodo.4726652>
- Goëau, H., Bonnet, P., & Joly, A. (2019). *Overview of LifeCLEF Plant Identification Task 2019: diving into Data Deficient Tropical Countries*. 2380(247). <https://hal.umontpellier.fr/hal-02283184>
- Goëau, H., Bonnet, P., & Joly, A. (2021). AI-based Identification of Plant Photographs from Herbarium Specimens. *Biodiversity Information Science and Standards*, 5, 1–4.
<https://doi.org/10.3897/BISS.5.73751>
- Goëau, H., Bonnet, P., & Joly, A. (2022). *Overview of PlantCLEF 2022: Image-based plant identification at global scale*. 3180(153), 1916–1928. <https://hal-lirmm.ccsd.cnrs.fr/lirmm-03793591>
- Jardín Botánico de Bogotá. (2025). *Agricultura Urbana*. Jardín Botánico de Bogotá.
<https://jbb.gov.co/aplicacion-del-conocimiento/agricultura-urbana/>
- Joly, A., Goëau, H., Kahl, S., Picek, L., Lorieul, T., Cole, E., Deneu, B., Servajean, M., Durso, A., Bolon, I., Glotin, H., Planqué, R., de Castañeda, R. R., Vellinga, W. P., Klinck, H., Denton, T., Eggel, I., Bonnet, P., & Müller, H. (2021). Overview of LifeCLEF 2021: an evaluation of Machine-Learning based Species Identification and Species Distribution Prediction. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and*

- Lecture Notes in Bioinformatics*), 12880, 371–393. https://doi.org/10.1007/978-3-030-85251-1_24
- Joly, A., Goëau, H., Kahl, S., Picek, L., Lorieul, T., Cole, E., Deneu, B., Servajean, M., Durso, A., Glotin, H., Planqué, R., Vellinga, W. P., Navine, A., Klinck, H., Denton, T., Eggel, I., Bonnet, P., Šulc, M., & Hruz, M. (2022). Overview of LifeCLEF 2022: An Evaluation of Machine-Learning Based Species Identification and Species Distribution Prediction. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 13390, 257–285. https://doi.org/10.1007/978-3-031-13643-6_19
- Landon-Lane, C. (2005). *Los medios de vida crecen en los huertos*. Folleto de La FAO Sobre Diversificación 2. <https://www.fao.org/4/y5112s/y5112s00.htm#Contents>
- Muñoz, C. (2023). *Clasificación de enfermedades en cultivos de papa empleando redes neuronales convolucionales*. <https://repository.javeriana.edu.co/handle/10554/65257>
- Organización de las Naciones Unidas. (2025). *17 objetivos para transformar nuestro mundo*. Objetivos de Desarrollo Sostenible. <https://www.un.org/sustainabledevelopment/es/>
- Pantoja Bohórquez, C. P., Martínez Grisales, K. J., Rincón Vivas, J. P., & Boada Arias, L. V. (2024). Mujeres y Agricultura Urbana Comunitaria: un estudio de caso múltiple en Bogotá, Colombia. *Convergencia*, 31(4). <https://doi.org/10.29101/CRC.S.V31I0.22287>
- Pearson, K. D., Nelson, G., Aronson, M. F. J., Bonnet, P., Brenskelle, L., Davis, C. C., Denny, E. G., Ellwood, E. R., Goëau, H., Mason Heberling, J., Joly, A., Lorieul, T., Mazer, S. J., Meineke, E. K., Stucky, B. J., Sweeney, P., White, A. E., & Soltis, P. S. (2020). Machine Learning Using Digitized Herbarium Specimens to Advance Phenological Research. *Bioscience*, 70(7), 610–620. <https://doi.org/10.1093/BIOSCI/BIAA044>
- Ramírez, L. J. (2021, September 19). *¿Cuáles son las redes de agricultores y agricultoras de Bogotá? (foto) | Bogota.gov.co*. Alcaldía de Bogotá D.C. <https://bogota.gov.co/mi-ciudad/ambiente/cuales-son-las-redes-de-agricultores-y-agricultoras-de-bogota-foto>
- Rounsevell, M. D. A., Loveland, P. J., Mayr, T. R., Armstrong, A. C., Rosa, D. de la, Legros, J.-P., Simota, C., & Sobczuk, H. (2024). Overview of PlantCLEF 2024: multi-species plant identification in vegetation plot images. *PlantCLEF 2024*, 3740(187), 1978–1988. <https://doi.org/10.13039/501100000780>
- Secretaría Distrital de Ambiente & Observatorio Ambiental de Bogotá. (2022, May 22). *Huertas Urbanas: ¿Qué son y cuántas hay en Bogotá?* Observatorio Ambiental de Bogotá. <https://oab.ambientebogota.gov.co/huertas-urbanas-que-son-y-cuantas-hay-en-bogota/>
- Suache, J. (2022, December 29). *Agricultura urbana y periurbana: Una alternativa para las bogotanas | Bogota.gov.co*. Alcaldía de Bogotá D.C. <https://bogota.gov.co/mi-ciudad/ambiente/agricultura-urbana-y-periurbana-una-alternativa-para-las-bogotanas>
- Torres Vivas, D. M. (2018). *Inclusión De La Agricultura Urbana Sostenible En Bogotá Dentro Del Posacuerdo Colombiano. Estudio De Caso: Ensayo De Producción Técnica De Lulo A Escala Urbana*. <https://repository.udistrital.edu.co/server/api/core/bitstreams/5b37a41d-42ac-4b6e-891f-235b138c763e/content>