



IA al Servicio de las Comunidades: Modelo de Clasificación Automática de Plantas Cultivadas en Ecosistemas de Agricultura Urbana

Ana María Ochoa Muñoz
María Fernanda Izquierdo Aparicio

Trabajo de grado presentado a la facultad de ingeniería de la Pontificia Universidad Javeriana para
optar al título de:
Magister en Analítica para la Inteligencia de Negocios

Directores del Proyecto de Grado:
Juan Erasmo Gómez Morantes, PhD
Juan Pablo Pájaro Hernández
Katherine Cabrera Rodríguez
Néstor Armando Nova Arévalo, PhD

Pontificia Universidad Javeriana
Facultad de Ingeniería
Maestría en Analítica para la Inteligencia de Negocios

Entrega Final
Mayo 29 de 2025, Bogotá D.C.

Agradecemos a:
Nuestras familias por su apoyo incondicional,
A los profesores que nos acompañaron con su guía y compromiso,
Y al proyecto Terraza Verde por abrir sus puertas y brindarnos la oportunidad de desarrollar esta
investigación en un entorno real y significativo.

Tabla de contenido

Resumen.....	6
Abstract.....	6
1. Introducción.....	7
1.1. Metodología CRISP-DM.....	7
2. Comprensión del negocio	11
2.1. Introducción al problema.....	11
2.2. Análisis de la comunidad.....	11
2.3. Análisis Externo	13
2.4. Análisis Interno	15
2.5. Objetivos.....	17
2.6. Justificación y Generación de Valor para la Universidad y Comunidad	17
2.7. Tarea Analítica	18
2.8. Limitantes del proyecto	18
3. Comprensión de los datos	19
3.1. Recolección de datos iniciales.....	19
3.2. Exploración y descripción de datos iniciales	20
3.3. Exploración y descripción de las características de datos seleccionados.....	22
3.4. Verificación de calidad de datos seleccionados.....	24
4. Preparación de los datos	26
4.1. Integración y limpieza de múltiples fuentes de datos	26
4.2. Transformación de imágenes.....	27
4.3. Vista Minable	30
4.4. Flujo de datos detallado.....	30
5. Modelado	32
5.1. Selección de modelos de clasificación de imágenes.....	32
5.2. Construcción y Sintonización de modelos.....	40
6. Evaluación	46
6.1. Procesos de validación y evaluación de los modelos (entrenamiento y validación).....	46
6.2. Tablero de sintonización.....	49
6.3. Definición de Hiperparámetros.....	50
6.4. Flujo de datos detallado.....	51
6.5. Definición del mejor modelo	51
7. Despliegue.....	53
7.1. Prueba en campo.....	53
7.2. Flujo de datos detallado	55
8. Conclusiones y Recomendaciones	56
9. Referencias	58
10. Anexos	61
10.1. Visita a huertas urbanas	61
10.2. Diagrama Buyer persona	64
10.3. Detalle tablero de resumen de sintonización de modelos y resultados	65

Tabla de ilustraciones

Ilustración 1 - Ciclo de vida de minería de datos	8
Ilustración 2 - Diagrama de Flujo de Datos general.....	10
Ilustración 3 - Fotos de Ana María Ochoa Muñoz y Maria Fernanda Izquierdo con la comunidad de huerteros en sus visitas a las huertas.	12
Ilustración 4 - Distribución de Imágenes por Estado de Salud Cassava Leaf Disease Classification Dataset.....	23
Ilustración 5 - Distribución de Imágenes por Tipo de Enfermedad Cassava Leaf Disease Classification Dataset.....	23
Ilustración 6 - Distribución de Imágenes por Estado de Salud PlantVillage Dataset.....	24
Ilustración 7 - Distribución de Imágenes por Estado de Salud PlantPAD Dataset	24
Ilustración 8 - Distribución de imágenes por tipo de plantas en conjunto de datos final	27
Ilustración 9 - Distribución de imágenes por estado de salud en conjunto de datos final	27
Ilustración 10 - Distribución de imágenes por tipo de planta y estado de salud en conjunto de datos final	27
Ilustración 11 - Muestra de imágenes originales del conjunto de datos final	28
Ilustración 12 - Distribución del conjunto de datos final en subconjuntos de entrenamiento, validación y prueba.....	28
Ilustración 13 - Ejemplo de aplicación de transformaciones.....	29
Ilustración 14 - Muestra de algunas observaciones de la vista minable.....	30
Ilustración 15 - Flujo de Datos (Comprensión y preparación de datos).....	31
Ilustración 16 - Diagrama de Fases de Construcción CNNs	41
Ilustración17 - Ejemplo gráficas de Accuracy y pérdida (loss). Esta gráfica corresponde al Modelo 29 Unet.....	46
Ilustración 18 - Matriz de confusión. Esta gráfica corresponde al Modelo 29 (Versión conjunto de datos final – Balanceado- Unet).....	47
Ilustración19 - Muestreo de predicciones vs etiquetas reales. Esto corresponde al Modelo 29 (Versión conjunto de datos final – Balanceado- Unet)	48
Ilustración 20 – Gráfica de Curvas ROC por clase. Esta corresponde al Modelo 29 (Versión conjunto de datos final – Balanceado- Unet)	48
Ilustración 21 - Gráfico de resultados de experimentación	50
Ilustración 22 - Flujo de datos detallado (Comprensión, preparación de datos, modelado y evaluación)	51
Ilustración 23 - Huerteros utilizando la app "ConCiencia" para clasificación de imágenes de planta en huertas urbanas	54
Ilustración 24 - Screenshots de la app "Residuos ConCiencia" mostrando la prueba del modelo de clasificación de imágenes (modelo previo al modelo final seleccionado para despliegue)	55
Ilustración 25 - Flujo de datos detallado y completado con las fases de CRISP-DM (comprensión y preparación de datos, modelado, evaluación y despliegue)	55
Ilustración - Buyer Persona 1	64
Ilustración - Buyer Persona 2	64

Listado de tablas

Tabla -1 - Listado de plantas cultivadas en huertas urbanas del Proyecto Terraza Verde	13
Tabla -2 - Análisis PESTEL sobre huertas urbanas	13
Tabla -3 - Tabla Cinco Fuerzas de Porter.....	14
Tabla -4 - Resumen Cinco Fuerzas de Porter	15
Tabla -5 - Tabla Análisis DOFA huertas y app de clasificación de imágenes	15
Tabla -6 - Distribución de Imágenes por tipo de planta PlantVillage Dataset	23
Tabla -7 - Distribución de Imágenes por tipo de planta PlantPAD Dataset	24
Tabla -8 - Métricas de calidad imágenes seleccionadas	25

Tabla -9 - Resumen exploración y selección de datos	26
Tabla -10 - Resumen Estado del Arte	34
Tabla -11 - Resultados TAM Visita Cantarrana.....	54
Tabla -12 - Detalle tablero sintonización modelos y resultados.....	65

Resumen

Este trabajo presenta el desarrollo de una prueba de concepto para un modelo de redes neuronales convolucionales capaz de clasificar automáticamente imágenes de plantas cultivadas en huertos urbanos, utilizando la metodología CRISP-DM para su desarrollo e implementación. Esta investigación contribuye al proyecto "Framework para la gestión del conocimiento comunitario sobre residuos sólidos orgánicos, soportada por tecnologías 4.0", ya que el modelo entrenado y su función de predicción, que constituyen el entregable principal de este estudio, son integrados en la aplicación móvil "Residuos ConCiencia". Con este aporte, se busca fortalecer la gestión del conocimiento agrícola en comunidades urbanas asociadas al proyecto social "Terraza Verde", proporcionando una herramienta para que los huerteros puedan identificar las plantas que cultivan, lo cual mejorará su capacidad para optimizar el cuidado y el manejo de sus huertos, promoviendo prácticas sostenibles y eficientes en la agricultura urbana.

Palabras Clave: Aprendizaje profundo, clasificación de imágenes, huertos urbanos, redes neuronales convolucionales, agricultura urbana, gestión del conocimiento, CRISP-DM.

Abstract

This work presents the development of a proof-of-concept for a convolutional neural network model capable of automatically classifying images of plants grown in urban gardens, using the CRISP-DM methodology for its development and implementation. This research contributes to the project "Framework para la gestión del conocimiento comunitario sobre residuos sólidos orgánicos, soportada por tecnologías 4.0" since the trained model and its prediction function, which constitute the main deliverable of this study, are integrated into the mobile application "Residuos ConCiencia". This contribution seeks to strengthen agricultural knowledge management in urban communities associated with the "Terraza Verde" social project by providing a tool for gardeners to identify the plants they grow. This will improve their ability to optimize the care and management of their gardens, promoting sustainable and efficient practices in urban agriculture.

Keywords: Deep learning, image classification, urban gardens, convolutional neural networks, urban agriculture, knowledge management, CRISP-DM.

1. Introducción

El presente documento detalla el desarrollo de una prueba de concepto para un modelo de aprendizaje profundo destinado a la clasificación automática de imágenes de plantas cultivadas en huertos urbanos en las localidades de Usme y Rafael Uribe Uribe en Bogotá, Colombia. Esta prueba de concepto, que se desarrolla dentro de la participación de la Pontificia Universidad Javeriana en la Alianza CAOBA¹, apoya el desarrollo de la parte técnica del proyecto de investigación “Framework para la gestión del conocimiento comunitario sobre residuos sólidos orgánicos, soportada por tecnologías 4.0” liderado por los profesores Néstor Armando Nova Arévalo, PhD y Juan Erasmo Gómez Morantes, PhD, ambos también adscritos a la Pontificia Universidad Javeriana.

El proyecto de investigación, a su vez, apoya la iniciativa social Terraza Verde², liderada por la Fundación Skat³ y la Parroquia San Marcelino Champagnat ubicada en la localidad de Usme. El proyecto de investigación aporta a la iniciativa social el desarrollo y despliegue de la aplicación móvil “Residuos ConCiencia”, la cual ofrece a los miembros de la comunidad asociada a Terraza Verde una plataforma interactiva que facilita el acceso a información sobre compostaje y agricultura urbana, permitiendo a la comunidad compartir experiencias. La plataforma incluye un chatbot con inteligencia artificial para responder preguntas sobre gestión de residuos orgánicos y permite a los usuarios contribuir con imágenes de plantas cultivadas en las huertas urbanas, creando una base de datos visual para el aprendizaje colectivo (López Usa, 2024).

Esta prueba de concepto ya forma parte de la aplicación, ya que se ha integrado el modelo de clasificación de plantas seleccionado a la misma. De esta manera, los usuarios de “Residuos ConCiencia” cuentan ahora con una herramienta que les facilita la identificación de sus cultivos y les permite profundizar en el conocimiento de las especies que están cultivando. Se espera que, gracias a esta herramienta, la comunidad supere la dificultad actual para identificar las plantas en el huerto, lo que contribuirá al cuidado adecuado de las mismas. Además, se busca impulsar el uso de tecnologías emergentes, que son claves para superar las brechas de información, promover la apropiación del conocimiento y facilitar la adopción de buenas prácticas en la agricultura urbana. Al ofrecer una herramienta accesible, los huerteros podrán identificar sus cultivos con mayor facilidad, optimizar el manejo de sus huertas y prevenir enfermedades en sus plantas. De este modo, el proyecto no solo promueve el uso de la inteligencia artificial en la agricultura urbana, sino que también fomenta la apropiación del conocimiento y el desarrollo comunitario.

Con este contexto descrito, el objetivo principal de esta prueba de concepto, presentada como proyecto de grado, fue el diseño de una solución basada en un modelo de redes neuronales convolucionales que permitió identificar especies de plantas y su estado de salud (enfermas o saludables) a partir de imágenes, el cual fue entregado a los profesores Nova Arévalo y Gómez Morantes, para que fuera integrado a la app móvil “Residuos ConCiencia”.

1.1. Metodología CRISP-DM

Con el fin de abordar el desarrollo de esta prueba de concepto de forma completa, se utilizó la Metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), la cual describe un modelo de proceso ampliamente adoptado en proyectos de minería y ciencia de datos (Chapman et

¹ Centro de Excelencia y Apropiación en Big Data y Data Analytics (<https://www.alianzacaoba.co>)

² Terraza Verde es un proyecto de la Fundación Skat que tiene como objetivo apoyar a la comunidad para generar conciencia ambiental.

³ Fundación Skat: Organización suiza sin fines de lucro, con 20+ años en cooperación internacional, para desarrollo sostenible de poblaciones vulnerable (<https://skat-foundation.ch>)

al., 2000). Esta metodología proporcionó un enfoque estructurado y flexible a través de seis fases interconectadas, permitiendo iteraciones y retrocesos según las necesidades que este proyecto presentó.

CRISP-DM divide el ciclo de vida del desarrollo de proyectos de análisis de datos en seis fases definidas, lo que proporciona un marco metodológico robusto y sistemático (Instituto de ingeniería del conocimiento, 2025). La metodología está conceptualizada en niveles jerárquicos, donde cada fase se estructura en tareas generales que posteriormente se proyectan a tareas específicas. Esta organización facilita la planificación y seguimiento del proyecto, aunque la sucesión de fases no es necesariamente rígida, permitiendo iteraciones según las necesidades específicas del proyecto (Chapman et al., 2000). A continuación se ilustran las fases de esta metodología.




Ilustración 1 - Ciclo de vida de minería de datos

Imagen tomada de <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>

1.1.1. Las Seis Fases de CRISP-DM en esta Prueba de Concepto

Fase 1: Comprensión del Negocio

Esta primera fase es fundamental y posiblemente la más importante del proceso, pues en el contexto de esta prueba de concepto, consiste en definir claramente el problema a abordar, los objetivos y la pregunta que se busca resolver.

Durante esta etapa:

- Se identifica y comprende el contexto en el cual se ubica la prueba de concepto
- Se establecen los objetivos generales y específicos del proyecto
- Se realiza la justificación del proyecto
- Se definen de los requisitos y limitantes de la prueba de concepto

Fase 2: Comprensión de los Datos

Una vez definido el problema, se continua con el entendimiento de los datos disponibles para este trabajo. Esta fase implica:

- Recolectar los datos iniciales, en este caso imágenes de plantas.
- Explorar y describir las características de estas imágenes.
- Verificar la calidad de las mismas.

Todo esto es acompañado por la justificación de las fuentes seleccionadas y una descripción detallada de los conjuntos utilizados.

Fase 3: Preparación de los Datos

Esta fase consiste en transformar los datos en bruto en un conjunto de datos adecuado para el modelamiento y análisis. Entre las actividades principales a realizar se encuentran:

- Integración de múltiples fuentes de datos si es necesario
- Limpieza de datos (tratamiento de imágenes y sus metadatos)
- Transformación de imágenes (normalización, transformaciones geométricas y de intensidad, aplicación de filtros, etc.)
- Balanceo de datos (en caso de que se considere relevante)

Fase 4: Modelado

Durante esta fase, se selecciona y aplican diversas técnicas de modelado para responder a la prueba de concepto y pregunta planteadas. Estas actividades incluyen:

- Selección de modelos de clasificación de imágenes apropiados al contexto
 - Presentación del Estado del Arte
 - Definición y justificación de métricas de evaluación a utilizar
- Desarrollo de los modelos (construcción, entrenamiento y sintonización).

Fase 5: Evaluación

Esta fase va más allá de la evaluación técnica de los modelos, pues se centra en determinar si los resultados obtenidos cumplen con los objetivos establecidos inicialmente. Esto incluye:

- Evaluación de los resultados respecto a los criterios de éxito definidos a partir de la comparación entre distintos modelos para seleccionar el más adecuado.
- Revisión del proceso completo para identificar aspectos a mejorar.
- Determinación de los próximos pasos a seguir.
- Decisión sobre la implementación o refinamiento de los modelos.

En el contexto de esta prueba de concepto, esta fase permite reflexionar sobre las contribuciones del proyecto y su aplicabilidad según el contexto descrito.

Fase 6: Despliegue

La fase final se enfoca en la aplicación práctica de los resultados obtenidos. En este caso se centra en el proceso de entrega del material desarrollado a los profesores, prueba de campo con los usuarios finales y la correspondiente presentación formal del trabajo de grado, incluyendo conclusiones, limitaciones y recomendaciones para futuras investigaciones.

1.1.2. Flujo de datos

A partir de la adopción de la metodología CRISP-DM, este trabajo avanzó de manera natural hacia la construcción de un flujo de datos estructurado que guía el desarrollo de la prueba de concepto. La imagen que se muestra a continuación ilustra este flujo general, alineado con las seis fases del modelo desde la comprensión y preparación de los datos, pasando por el modelado y evaluación de los modelos, hasta llegar al despliegue de resultados. Cada etapa conecta con tareas específicas que permiten avanzar de forma iterativa y flexible.




Ilustración 2 - Diagrama de Flujo de Datos general.
Fuente: Elaboración Propia

Este esquema general se desarrolla en detalle a lo largo del documento, abordando las decisiones técnicas y metodológicas de cada componente del flujo. Desde una perspectiva pedagógica, especialmente orientada a otros estudiantes de la maestría que realizarán su tesis y a los investigadores del proyecto al que está adscrita esta prueba de concepto, este enfoque resulta de gran valor. En este sentido, se destaca que esta evolución responde a un carácter educativo, con el objetivo de dejar todo claramente explicado para que otros puedan utilizarlo fácilmente y darle continuidad al proyecto, tal como se ha discutido en los espacios de dirección con los profesores Nova Arévalo y Gómez Morantes.

1.1.3. Organización del documento

A partir de esta introducción, el contenido del documento se estructura siguiendo las fases de la metodología CRISP-DM adoptada. En el Capítulo 2 se desarrolla la comprensión del negocio, donde se analiza en profundidad el contexto, los objetivos y las motivaciones del proyecto. El Capítulo 3 se centra en la comprensión de los datos, proporcionando detalles sobre el origen, las características y la calidad de las imágenes utilizadas. En el Capítulo 4 se describe la preparación de los datos, que abarca los procesos de transformación y adecuación de las imágenes para su posterior análisis. El Capítulo 5 está dedicado al modelamiento, donde se explican las técnicas y modelos de aprendizaje profundo aplicados. El Capítulo 6 se enfoca en la evaluación, analizando el desempeño de los modelos construidos en relación con los objetivos establecidos y la elección del modelo a usar en la aplicación de “Residuos ConCienCIA”. El Capítulo 7 trata el despliegue, que incluye el plan de entrega y socialización de los resultados del modelo a los actores involucrados en el proyecto y la realización de una prueba de campo de la integración del modelo a la aplicación con usuarios finales. Finalmente, el Capítulo 8 presenta las conclusiones y recomendaciones, donde se reflexiona sobre los aprendizajes obtenidos durante el proceso y se proponen líneas de trabajo futuro, manteniendo la estructura iterativa y flexible que caracteriza a la metodología CRISP-DM.

2. Comprensión del negocio

2.1. Introducción al problema

La agricultura urbana comprende actividades agrícolas desarrolladas dentro de las ciudades, sin importar su tamaño o propósito. Según la FAO (Landon-Lane, 2005) estas prácticas abarcan desde pequeños huertos familiares hasta iniciativas comunitarias de mayor escala. En Bogotá, las huertas urbanas se han consolidado como una práctica en aumento que promueve la producción de alimentos saludables en espacios urbanos variados, como suelos, terrazas o edificios. Actualmente Bogotá cuenta con más de 4.000 huertas y alrededor de 20.000 huerteros, posicionándose como referente en agricultura urbana en Latinoamérica (Secretaría Distrital de Ambiente & Observatorio Ambiental de Bogotá, 2022)

Sin embargo, las huertas urbanas enfrentan múltiples desafíos que limitan su potencial; entre estos se destacan: las limitaciones de espacio debido a la escasez de terrenos adecuados, la contaminación del suelo en algunas zonas que afecta la calidad de los cultivos, el acceso limitado al agua especialmente en períodos de sequía, los retos de sostenibilidad económica frente a mercados establecidos, y la falta de conocimiento técnico de algunos huerteros. Esta última problemática se evidenció en el transcurso del primer trabajo de campo realizado en el Centro de Desarrollo Comunitario Fe y Alegría en la localidad de Rafael Uribe Uribe, con la comunidad adscrita al proyecto de Terraza Verde y que apoya el proyecto de investigación mencionado en la introducción (revisar [10.1 Anexo](#) para detalle del trabajo en campo realizado como parte de esta prueba de concepto).

2.2. Análisis de la comunidad

Entendiendo que esta prueba de concepto se concentra en la comunidad que atiende el proyecto de Terraza Verde, es importante comprender el contexto de la misma, la cual se encuentra entre las localidades de Rafael Uribe Uribe y Usme.

Por un lado, la localidad de Usme, ubicada en el suroriente de Bogotá, cuenta con una población estimada de 414.995 habitantes para el año 2024 según la Secretaría Distrital de Salud (2025). Esta comunidad presenta una distribución diversa en términos de edad, con un alto porcentaje de adultos (40%) y jóvenes (25,8%)(Secretaría de integración social, 2023). Adicionalmente, es importante resaltar que aproximadamente el 51% de la población son mujeres y el 49% hombres. También cuenta con diversidad étnica, incluyendo población indígena y afrodescendiente. La mayoría de sus habitantes pertenecen a estratos socioeconómicos bajos, con índices elevados de pobreza multidimensional. Además, la localidad registra situaciones sociales críticas, como un alto número de casos de discapacidad infantil y violencia intrafamiliar (Secretaría de Salud de Bogotá, 2024).

En complemento, la localidad de Rafael Uribe Uribe, ubicada en el centro-oriente de Bogotá, cuenta con una población estimada de 391.588 habitantes para el año 2024 con una distribución del 49% de hombres y 51% mujeres. La distribución etaria evidencia una pirámide regresiva, con una alta proporción de adultos entre 25 y 34 años, así como un crecimiento notable de personas entre los 40 y 70 años, lo que refleja una transición demográfica avanzada (Secretaría de Salud de Bogotá & Observatorio de Salud de Bogotá, 2025). La mayoría de los habitantes pertenecen a estratos socioeconómicos bajos, destacando el estrato 2 (45,2%) y el estrato 3 (32,3%).

Este contexto sociodemográfico de ambas localidades acentúa la importancia estratégica de las huertas urbanas como una alternativa sostenible que no solo podría contribuir a la seguridad alimentaria local, sino también ofrecer soluciones concretas frente a las vulnerabilidades socioeconómicas y ambientales que enfrentan sus habitantes.

2.2.1. Caracterización de usuarios

Con el fin de entender el contexto de los usuarios que usan la app “Residuos ConCienCIA”, se realizaron dos visitas a dos huertas urbanas afiliadas al proyecto de Terraza Verde. La primera visita se realizó el 22 de Marzo del 2025 a la huerta ubicada en el barrio Palermo Sur de la localidad de Rafael Uribe Uribe, que se encuentra adentro del Centro de Desarrollo Comunitario Fe y Alegría – CEDECO, el cual es un espacio público que promueve el desarrollo de capacidades individuales y comunitarias, ofreciendo oportunidades para la mejora de ingresos, el uso del tiempo libre y el fortalecimiento del tejido social (Ideca: Infraestructura de Datos Espaciales para el Distrito Capital, 2022). La segunda visita fue realizada el 17 de Mayo de 2025 a la huerta ubicada dentro del Parque Ecológico Cantarrana, el cual está localizado al sur de la ciudad, en la localidad de Usme. Este parque es un atractivo ambiental de Bogotá, y un espacio de encuentro e integración para la comunidad, donde niños, niñas, jóvenes y adultos, pueden disfrutar de una amplia reserva ambiental de 76 hectáreas y el cual incluye un centro social y huertas urbanas pertenecientes a diferentes grupos comunitarios, entre ellos Terraza Verde (Acueducto y Alcantarillado de Bogotá, 2025).

Durante las visitas, las autoras obtuvieron una mejor comprensión el perfil de los usuarios finales del modelo de clasificación de plantas mediante imágenes. Fue posible conocer e interactuar con el grupo de huerteros que forma parte activa de esta comunidad, en su mayoría personas entre los 55 y 65 años, portadoras de conocimientos ancestrales relacionados con el uso y el cultivo de planta, y quienes gracias a su participación en el proyecto Terraza Verde⁴ han fortalecido sus saberes en compostaje, agricultura urbana y prácticas de reciclaje, tanto en sus hogares como en las huertas. También se conocieron algunas de las personas más jóvenes del grupo, quienes están en proceso de aprender sobre el cultivo en huertas y agricultura urbana, y quienes se encuentra en un proceso de apropiación del conocimiento transmitido por los miembros con mayor experiencia en una dinámica intergeneracional valiosa.



Ilustración 3 - Fotos de Ana María Ochoa Muñoz y Maria Fernanda Izquierdo con la comunidad de huerteros en sus visitas a las huertas.

Fuente: Elaboración Propia

Durante el tiempo en ambas huertas, se exploraron y se identificaron cuáles especies se cultivan allí, y en las demás huertas del proyecto Terraza Verde. Estas plantas comprenden frutas, hortalizas, tubérculos y aromáticas, que suman mas de 40 especies. En la Tabla 1 se enumeran la plantas alimenticias mas importantes y abundantes de los huertos.

⁴ Skat Foundation. (2021). *Terraza Verde, Colombia*. Skat Foundation. <https://skat-foundation.ch/terrazaverde-colombia/>

Tabla-1 - Listado de plantas cultivadas en huertas urbanas del Proyecto Terraza Verde

Plantas Alimenticias en Huertas de Terraza Verde					
Acelga	Cebolla Cabezona	Fresa	Maíz	Pepino Cohombro	Ruibarbo
Aguacate	Cebolla Larga	Fríjol	Manzanilla	Pepino de Guiso	Tomate
Ajo	Cebollín	Gulpa	Menta	Perejil	Tomate de Arbol
Albahaca	Cicuta	Hierbabuena	Nabo	Rábano	Uchuva
Berenjena	Cilantro	Kale	Orégano	Remolacha	Yuca
Brócoli	Coliflor	Lavanada	Papa	Repollo	Zanahoria
Caléndula	Curuba	Lechuga	Papayuela	Romero	Zuchinni (Calabacín)

A partir de las conversaciones sostenidas con la comunidad, se logró profundizar en la comprensión del vínculo que estas personas han construido con la aplicación móvil “Residuos ConCienCIA”. Esta herramienta fue desarrollada con base en los saberes y conocimientos propios de la comunidad, y en específico, los huerteros participaron activamente en su diseño y salida a producción. Actualmente, la comunidad se encuentra en un proceso de aprendizaje acerca del uso de la aplicación, especialmente en el caso de las personas mayores quienes a su vez aprenden de otros temas tecnológicos que van de la mano con el uso de una app móvil. A pesar de estos retos, la comunidad avanza hacia el uso de la app como un repositorio vivo de conocimiento y como una herramienta para la apropiación colectiva de sus prácticas y saberes. No obstante, se pudo identificar una limitación importante: la mayoría de los huerteros no cuentan con acceso a internet en sus dispositivos móviles, lo que dificulta el uso de la aplicación Residuos ConCienCIA y limita su interacción con herramientas digitales.

Con toda esta información, se realizaron dos diagramas Buyer Persona con los dos tipos de usuario típicos que se adjunta en los anexos [10.2 Diagrama Buyer persona](#) con el fin de tener la caracterización documentada y que fuera guía para el proceso de esta prueba de concepto.

2.3. Análisis Externo

Ahora bien, teniendo una clara comprensión de los usuarios, es también importante entender el contexto y los factores externos que impactan las huertas urbanas y el uso de herramientas de clasificación de imágenes en estos contextos. Por esta razón, se elabora un análisis PESTEL (Político, Económico, Social, Tecnológico, Ecológico y Legal) y un análisis de las Cinco Fuerzas de Porter, los cuales permiten evaluar sistemáticamente los factores externos que influyen en el tópico que tiene este proyecto.

2.3.1. PESTEL

El análisis PESTEL apoya la comprensión de la situación actual de las huertas urbanas y los factores externos que impactan este contexto. Esto es relevante porque es el ambiente donde se da lugar el uso de la app “Residuos ConCienCIA” y el cual puede afectar el uso de la misma para la clasificación automática de imágenes de diversas plantas.

Tabla -2 - Análisis PESTEL sobre huertas urbanas

Político	Apoyo gubernamental a la agricultura urbana: El distrito de Bogotá promueve la agricultura urbana como estrategia de seguridad alimentaria, especialmente en localidades como Usme.
-----------------	---

	- Políticas ambientales: Existen políticas locales de sostenibilidad que pueden beneficiar el proyecto (ej. Plan de Desarrollo Distrital, políticas de economía circular). - Estabilidad política local y distrital: Aunque hay cambios de administración cada cuatro años, los programas de agricultura urbana han tenido continuidad. - Relación con Juntas de Acción Comunal (JAC): Las JAC pueden apoyar o frenar la implementación según el grado de participación comunitaria. - Las políticas públicas también juegan un papel crucial en el desarrollo de la agricultura urbana en Bogotá. A través del Acuerdo 605 del 27 de agosto de 2015, se han establecido lineamientos para fomentar programas agroecológicos en áreas urbanas y periurbanas. Sin embargo, su implementación ha sido desigual y requiere un mayor compromiso por parte del gobierno local.
Económico	- Recursos limitados en la zona: Usme es una de las localidades con menores ingresos, lo que puede limitar el acceso a tecnología o conectividad. - Oportunidades de empleo verde: Las huertas pueden generar microempleo o fortalecer economías locales alrededor de los huertos. Actualmente en Terrazas Verdes los huerteros dan a conocer sus emprendimientos a través de ferias. - Disponibilidad de financiación: Hay fondos del distrito, ONGs, y cooperación internacional para proyectos de innovación social y sostenibilidad.
Social	- Interés comunitario por la agricultura: La agricultura urbana tiene una fuerte raíz social en Usme y Rafael Uribe Uribe, con comunidades organizadas y saberes tradicionales. - Nivel de alfabetización digital: Puede haber brechas en el manejo de herramientas tecnológicas empleadas para el sostenimiento de huertas urbanas; se requeriría formación. - Identidad cultural y relación con la tierra: Muchas familias tienen prácticas agrícolas tradicionales que pueden darse a conocer dentro la comunidad.
Tecnológico	- Acceso a dispositivos: Puede ser limitado; sería importante considerar modelos que funcionen en dispositivos móviles de gama media o baja. - Conectividad a internet: No siempre es estable o accesible en ciertas zonas, por lo que se podría requerir que la aplicación funcione offline. - Adopción de IA y tecnología en la comunidad: Puede haber resistencia inicial, pero también mucho potencial si se demuestra utilidad práctica. - Uso de herramientas abiertas: El uso de software libre y datasets abiertos facilitaría la escalabilidad del proyecto.
Ecológico	- Preservación de especies nativas: La identificación de plantas puede ayudar a conservar la biodiversidad local. - Cambio climático: Afecta la disponibilidad de especies y la planificación de cultivos, lo que podría integrarse al análisis de datos del proyecto. - Educación ambiental: El proyecto puede ser un vehículo educativo para niños y jóvenes sobre sostenibilidad.
Legal	- Protección de datos personales: Si se recopilan datos de usuarios, se deben cumplir normativas como la Ley 1581 de 2012 (protección de datos en Colombia). - Propiedad intelectual del modelo: Definir licencias y derechos de uso si se trabaja con terceros o si se libera a la comunidad.

2.3.2. Cinco Fuerzas de Porter

El análisis de las Cinco Fuerzas de Porter permite evaluar el nivel de competitividad y la rentabilidad potencial en el contexto específico de las huertas urbanas bogotanas y el uso que tienen con aplicaciones móviles o software de agricultura urbana. Esta herramienta aporta claridad estratégica sobre las relaciones y dinámicas de mercado que influyen en la sostenibilidad económica y operativa del proyecto y de la aplicación a la cual se apoya con la presente prueba de concepto.

Tabla -3 - Tabla Cinco Fuerzas de Porter

Amenaza de nuevos competidores
- La barrera tecnológica no es muy alta gracias a herramientas de código abierto como TensorFlow, PyTorch y modelos preentrenados. - Sin embargo, desarrollar un modelo preciso y específico para una región (como localidades de la ciudad de Bogotá, i.e. Usme y Rafael Uribe Uribe) requiere datos locales, conocimiento técnico y validación, lo que puede proteger el proyecto de copias genéricas. - Otros proyectos de agricultura urbana o aplicaciones de reconocimiento de plantas podrían entrar, pero pocas están contextualizadas al entorno urbano colombiano.
Poder de negociación de los proveedores
- En este caso, los <i>proveedores</i> podrían ser: - Proveedores de datos (imágenes, etiquetas, anotadores humanos).

⁵ Formula los lineamientos para institucionalizar el programa de agricultura urbana y periurbana agroecológica de manera sostenible y de bajos costos para la ciudad.

○ Infraestructura tecnológica (nube, dispositivos móviles, almacenamiento). • Dependencia de datasets abiertos. • El poder de negociación aumenta si se necesitan equipos o servicios muy específicos (como GPU para entrenamiento o anotación especializada).
Poder de negociación de los clientes o usuarios
• Los <i>clientes</i> pueden ser: ○ Usuarios de la aplicación (campesinos urbanos, estudiantes, comunidad). ○ Entidades aliadas (ONGs, gobierno, colegios, universidades). • En general, si la aplicación es gratuita y de valor práctico (reconocer plantas con el celular), el poder de los usuarios es bajo. • Si el proyecto requiere financiación o colaboración con actores públicos o privados, su poder aumenta.
Amenaza de productos o servicios sustitutos
• Ya existen aplicaciones como PlantNet, PictureThis, iNaturalist, etc., que hacen reconocimiento de plantas por imagen. • Sin embargo, la mayoría no están entrenadas con plantas propias de huertas urbanas bogotanas ni incluyen contenido que ha aportado la comunidad. • La ventaja competitiva podría estar en el enfoque local, educativo, sin fines de lucro y de soberanía tecnológica.
Rivalidad entre competidores existentes
• En Colombia o en Bogotá hay pocos proyectos similares aplicando inteligencia artificial a huertas urbanas. • En el entorno académico o de innovación social, la competencia es más colaborativa. • Si se escala el proyecto (por ejemplo, como aplicación comercial), la competencia internacional aumenta.

En resumen, se puede concluir lo siguiente:

Tabla 4 - Resumen Cinco Fuerzas de Porter

Fuerza	Nivel de presión	Comentario clave
Amenaza de nuevos competidores	Medio	Se necesitan datos locales y entrenamiento, lo cual protege.
Poder de proveedores	Bajo-Medio	Puede reducirse dependencia usando datos abiertos y open-source.
Poder de los clientes	Medio	Bajo si es una aplicación social, mayor si se depende de financiación.
Amenaza de sustitutos	Alto	Existen aplicaciones similares, pero no localizadas.
Rivalidad con competidores	Medio-Bajo	Competencia limitada en el entorno local y social.

2.4. Análisis Interno

Continuando, fue relevante identificar cuáles eran los factores internos al proyecto de investigación y la iniciativa social que encapsulan esta prueba de concepto, con el objetivo de poder potencializar correctamente factores claves de éxito para el despliegue y continuidad de uso del modelo que se entregó. Para esto se realizó un análisis DOFA (Debilidades, Oportunidades, Fortalezas y Amenazas) el cual ofrece una perspectiva completa y estratégica sobre el contexto específico de las huertas urbanas bogotanas y el uso de aplicaciones de clasificación de imágenes.

Tabla -5 - Tabla Análisis DOFA huertas y app de clasificación de imágenes

Fortalezas (F)	Debilidades (D)
F1. Enfoque local y contextualizado a huertas urbanas de Bogotá. F2. Uso de tecnologías de código abierto y modelos preentrenados. F3. Potencial de impacto social y educativo (educación ambiental, biodiversidad). F4. Apoyo institucional y comunitario a la agricultura urbana.	D1. Limitado acceso a dispositivos y conectividad en zonas vulnerables. D2. Brecha de alfabetización digital en la comunidad. D3. Dependencia de datos etiquetados/locales para lograr buen rendimiento. D4. Escasa visibilidad del proyecto frente a apps comerciales ya consolidadas.
Oportunidades (O)	Amenazas (A)
O1. Apoyo del gobierno local y ONGs a la agricultura urbana y economía circular. O2. Disponibilidad de fondos de innovación social y educación ambiental. O3. Interés creciente por sostenibilidad, soberanía alimentaria y empleo verde. O4. Avances tecnológicos en IA accesibles para comunidades y estudiantes.	A1. Existencia de aplicaciones sustitutas globales (PlantNet, iNaturalist, etc.). A2. Cambios en políticas públicas o poca continuidad institucional. A3. Dificultad para escalar el modelo fuera del contexto local. A4. Falta de infraestructura o apoyo técnico en zonas rurales o periurbanas.

A partir de los elementos identificados en el análisis DOFA, se vuelve evidente que el desarrollo e implementación de una solución tecnológica como “Residuos ConCiencia” no solo debe responder a las condiciones internas del proyecto, sino también posicionarse estratégicamente frente a otras aplicaciones existentes en el ecosistema digital. Por esta razón, resulta pertinente realizar un análisis comparativo que permita dimensionar el valor diferencial de la propuesta frente a alternativas consolidadas como PlantNet, PictureThis e iNaturalist. Esta comparación no solo evidencia las fortalezas competitivas del modelo propuesto, sino que también ayuda a identificar vacíos y oportunidades de mejora en función de las amenazas y debilidades previamente expuestas.

- PlantNet
 - **Función principal:** Identificación de plantas mediante reconocimiento de imágenes.
 - **Ventajas:** Amplia base de datos botánica, facilidad de uso, y reconocimiento rápido de especies.
 - **Limitaciones:** No ofrece diagnóstico profundo del estado de salud de las plantas ni funcionalidades específicas relacionadas con la gestión de residuos sólidos orgánicos o prácticas agrícolas sostenibles.
 - **Comparativa con Residuos ConCiencia:** *Residuos ConCiencia* incorporará identificación de especies y evaluará el estado de salud de la planta, combinando el uso de inteligencia generativa para ofrecer recomendaciones específicas en tiempo real. También se especializa en la gestión comunitaria de residuos sólidos orgánicos.
- PictureThis
 - **Función principal:** Reconocimiento e identificación de plantas y plagas mediante inteligencia artificial.
 - **Ventajas:** Ofrece diagnóstico básico de problemas de salud vegetal, recordatorios personalizados para el cuidado de las plantas.
 - **Limitaciones:** Está orientada principalmente a jardinería doméstica, sin una orientación comunitaria o enfocada en gestión sostenible de residuos.
 - **Comparativa con Residuos ConCiencia:** *Residuos ConCiencia*, además del diagnóstico de salud vegetal, promueve la colaboración comunitaria y la educación ambiental, alineándose específicamente con el enfoque del programa Terraza Verde.
- iNaturalist
 - **Función principal:** Red colaborativa para la identificación de plantas y animales, fomentando la participación ciudadana en ciencia.
 - **Ventajas:** Enfoque colaborativo, amplio soporte de la comunidad científica, base de datos extensa.
 - **Limitaciones:** No provee información directa sobre gestión de residuos, prácticas agrícolas urbanas específicas ni diagnósticos personalizados sobre el estado de salud de las plantas.
 - **Comparativa con Residuos ConCiencia:** Aunque ambas comparten un enfoque colaborativo, *Residuos ConCiencia* está específicamente diseñada para contextos locales de agricultura urbana y gestión de residuos orgánicos, proporcionando herramientas avanzadas como inteligencia generativa para una experiencia más personalizada y educativa.

De lo anterior se puede concluir que la aplicación *Residuos ConCiencia* se destaca por integrar funcionalidades de identificación y diagnóstico del estado de salud de plantas mediante inteligencia artificial y aprendizaje profundo, combinadas con una plataforma colaborativa para la gestión sostenible de residuos orgánicos. Este enfoque integral y comunitario es especialmente útil para programas como Terraza Verde, permitiendo no solo la identificación botánica sino también la capacitación continua y la activa participación ciudadana en la agricultura urbana sostenible.

2.5. Objetivos

2.5.1. Objetivo General

Para el proyecto de IA al Servicio de las Comunidades: Modelo de Clasificación Automática de Plantas Cultivadas en Ecosistemas de Agricultura Urbana se ha definido el siguiente objetivo general:

Desarrollar una prueba de concepto de una solución basada en aprendizaje de máquina para la clasificación automática, en un periodo de 4 meses, para la clasificación automática de imágenes de plantas cultivadas en huertas urbanas del proyecto Terraza Verde, capaz de identificar la especie y su estado de salud con un desempeño mínimo de 70% de Accuracy.

2.5.2. Objetivos Específicos

1. Preparar un conjunto de datos de al menos 5.000 imágenes de plantas (cubriendo al menos 5 especies y dos condiciones: saludable y enferma) correspondiente a especies que se encuentran en huertas urbanas, en un periodo máximo de 10 semanas, asegurando su calidad y diversidad para el entrenamiento de modelos.
2. Evaluar al menos cuatro versiones de modelos de aprendizaje profundo midiendo su rendimiento con la métrica de accuracy y seleccionando el mejor modelo en términos de desempeño y capacidad de generalización.
3. Entregar el modelo seleccionado, entrenado y documentado, para su incorporación posterior en la App "Residuos ConCiencia" al concluir el presente trabajo.
4. Evaluar el modelo desarrollado con los usuarios finales con el fin de garantizar su consistencia y coherencia con los requerimientos de las comunidades locales del programa Terraza Verde.

2.6. Justificación y Generación de Valor para la Universidad y Comunidad

El presente proyecto se alinea con los objetivos estratégicos de la Pontificia Universidad Javeriana, particularmente en su misión de servicio a la sociedad y su compromiso con la innovación y el desarrollo tecnológico con impacto social. A través del desarrollo de un modelo de clasificación automática de imágenes de plantas, embebido en la aplicación *Residuos ConCiencia*, se generan beneficios tanto para la comunidad como para la universidad.

Para la comunidad, esta iniciativa permite fortalecer el conocimiento sobre agricultura urbana mediante herramientas accesibles basadas en inteligencia artificial, facilitando la identificación de especies y la apropiación de buenas prácticas agrícolas. De esta manera, se empodera a las comunidades locales, mejorando su acceso a la información ambiental y contribuyendo a su calidad de vida. Además, la implementación de tecnologías emergentes se presenta como una oportunidad clave para reducir la brecha digital y social, facilitando la apropiación del conocimiento y el uso de herramientas tecnológicas en comunidades marginadas.

Para la Universidad, este proyecto refuerza su posicionamiento como líder en investigación aplicada en inteligencia artificial y análisis de datos. A través de su participación estratégica en la Alianza CAOBA, la Pontificia Universidad Javeriana fortalece su presencia en proyectos de big data y analítica avanzada, consolidando su papel en el desarrollo de soluciones innovadoras con impacto real.

En términos específicos, el proyecto contribuye directamente a:

- **Fortalecimiento del conocimiento comunitario:** Promueve la apropiación y compartición de conocimientos sobre agricultura urbana entre los miembros de la comunidad.
- **Cierre de la brecha digital:** Reduce la disparidad en el acceso y uso de herramientas tecnológicas al llevar inteligencia artificial a comunidades marginadas.
- **Apoyo a la sostenibilidad ambiental:** Facilita la gestión de residuos orgánicos y la agricultura urbana, promoviendo prácticas más sostenibles y contribuyendo a la seguridad alimentaria local.
- **Generación de datos valiosos:** La base de datos visual de imágenes de plantas, construida con el conocimiento de los agricultores, puede ser utilizada para investigación y desarrollo en agronomía urbana.
- **Mejora de la eficiencia agrícola:** La identificación automática de plantas permite a los huerteros urbanos tomar decisiones más informadas sobre el manejo de cultivos.

El proyecto se alinea con tendencias globales que impulsan la agricultura sostenible y el uso de tecnologías para el desarrollo comunitario (Organización de las Naciones Unidas, 2025). Además, la colaboración con la Fundación Skat asegura su sostenibilidad y escalabilidad, permitiendo que más comunidades puedan beneficiarse en el futuro.

2.7. Tarea Analítica

La tarea analítica principal de este proyecto es la clasificación multiclase automática de imágenes de plantas alimenticias saludables o enfermas en huertas urbanas con un modelo de aprendizaje profundo.

2.7.1. Pregunta Analítica

¿Cómo construir un modelo de aprendizaje automático profundo para clasificar imágenes de plantas alimenticias y su estado (sana o enferma)?

Hipótesis:

Se puede construir un modelo de aprendizaje automático profundo para para clasificar imágenes de plantas alimenticias y su estado (sana o enferma) a partir del uso de metodología CRISP-DM la cual comprende tanto los aspectos de minería de datos como de contexto de negocio.

2.8. Limitantes del proyecto

Este proyecto se centra en la clasificación de imágenes de plantas alimenticias, abordando tanto la identificación de especies como la detección del estado de salud de las plantas (enfermas o saludables). El modelo de aprendizaje profundo desarrollado está especializado en esta tarea específica, sin incluir otros aspectos de la agricultura urbana. La prueba de concepto culminó con la entrega de la documentación del modelo y las instrucciones de uso; sin embargo, la integración del modelo en la aplicación "Residuos ConCienCIA" es responsabilidad de los profesores y desarrolladores de la misma.

El entrenamiento del modelo dependió de la cantidad de especies de plantas identificadas en las huertas visitadas y de la disponibilidad de datos abiertos consultados. Por lo tanto, si se requiere identificar nuevas especies, será necesario actualizar el modelo con nuevos datos y realizar nuevamente los procesos de entrenamiento, validación y prueba. Finalmente, como se detalla en el capítulo de Evaluación, el modelo no clasifica el tipo de enfermedad de las plantas seleccionadas, debido a los bajos rendimientos observados en el proceso iterativo de modelado, los cuales no se alineaban con los objetivos inicialmente planteados.

3. Comprensión de los datos

Siguiendo con la estructura de la metodología CRISP-DM, una vez definidos los objetivos y el contexto del proyecto, se continuó con la fase de comprensión de los datos. Esta etapa tenía como finalidad identificar, explorar y evaluar las fuentes de datos disponibles para asegurar su pertinencia y calidad en relación con la prueba de concepto planteada. En este caso, el proceso se centró en la recolección de imágenes de plantas, y se desarrolló en varias etapas que permitieron seleccionar las bases de datos más adecuadas para el enfoque del proyecto.

A continuación, se describen las decisiones y criterios aplicados durante esta fase:

3.1. Recolección de datos iniciales

Para la delimitación del conjunto de datos base, se realizó una exploración progresiva durante 10 semanas de distintas fuentes abiertas. Este proceso permitió identificar las bases de datos más alineadas con los objetivos del proyecto, priorizando aquellas que ofrecieran imágenes de especies cultivadas en huertas urbanas y que contaran con diversidad en cuanto a condiciones fisiológicas. A continuación, se describen los momentos de este proceso:

1. Exploración inicial de Pl@ntNet⁶ (Fecha inicial de revisión: Febrero 2025): Se inició con la revisión de la fuente abierta Pl@ntNet, la cual fue referida por los profesores Nova y Gómez. No obstante, la base de datos de esta fuente contenía principalmente imágenes de plantas ornamentales, que no se ajustaban al enfoque de la prueba de concepto, centrada en especies cultivadas en huertas urbanas.
2. Evaluación del conjunto de datos de la competencia Cassava Leaf Disease Classification en Kaggle⁷ (Fecha inicial de revisión: Febrero 2025): A continuación, se analizó el conjunto de datos Cassava, el cual incluía exclusivamente imágenes de hojas de yuca. Dado su alcance limitado, pero entendiendo el proceso y que las huertas de Terraza Verde cultivan esta especie, se decide continuar usando en la parte exploratoria este dataset.
3. Incorporación de datos de PlantVillage⁸ (Fecha inicial de revisión: Marzo 2025): Con el fin de ampliar el volumen de datos disponibles, se recurrió a la base de datos abierta PlantVillage. Esta contiene 14 especies divididas en saludables y enfermas con diversos tipos de enfermedad, lo cual resultaba en 38 grupos de imágenes relacionadas con especies, estados fisiológicos y tipos de enfermedades.
4. Acceso a PlantPAD⁹ (Fecha inicial de revisión: Abril 2025): Finalmente, se gestionó el acceso a la base de datos PlantPAD a través de comunicación por correo electrónico con el profesor Qi Wang Ph.D¹⁰, que incluye 40 etiquetas similares a las de PlantVillage. De este conjunto, se identificaron tres especies pertinentes que se ajustaban al alcance del proyecto de grado.

⁶ Pl@ntNet: <https://zenodo.org/records/5645731>

⁷ Cassava Leaf Disease Classification Competition: <https://www.kaggle.com/competitions/cassava-leaf-disease-classification/data>

⁸ PlantVillage: <https://github.com/spMohanty/PlantVillage-Dataset/tree/master/raw>

⁹ PlantPAD: https://plantpad.samlab.cn/image_down.html

¹⁰ Special-term professor en el State Key Laboratory of Public Big Data, Guizhou University, China

3.2. Exploración y descripción de datos iniciales

1. Datos *Pl@ntNet*

El conjunto de datos *Pl@ntNet*-300K representa una valiosa colección de imágenes botánicas alojada en la plataforma Zenodo, diseñada específicamente para investigación en clasificación de imágenes con alta ambigüedad. Esta base de datos ha sido construida a partir del observatorio ciudadano *Pl@ntNet* y ofrece recursos significativos para investigadores en aprendizaje automático y ciencias botánicas (Garcin et al., 2021). Este dataset contiene 306.146 imágenes que abarcan 1.081 especies de plantas diferentes, representando una amplia diversidad de la flora mundial, lo cual es importante para aplicaciones con un alcance amplio pero lo cual es contraproducente para aplicaciones como la del presente proyecto que requiere de un enfoque muy local a las especies de las huertas ya mencionadas.

Algunas características distintivas del conjunto de datos *Pl@ntNet*-300K:

- Desequilibrio de clases y distribución de cola larga:
 - El conjunto de datos presenta un desequilibrio significativo, con pocas especies que concentran la mayoría de las imágenes y muchas especies representadas por pocos ejemplos.
 - Esta distribución desigual, reflejada en la curva de Lorenz, plantea un desafío para los algoritmos de aprendizaje automático.
- Alta ambigüedad visual entre especies:
 - Existe una gran similitud visual entre muchas especies, especialmente dentro del mismo género taxonómico, lo que dificulta la identificación incluso para expertos.
 - Factores como la variabilidad estacional, fotografías parciales, variaciones de color y la calidad variable de las imágenes contribuyen a esta ambigüedad.
 - Esto causa incertidumbre aleatoria (información parcial) y epistémica (errores del algoritmo por falta de datos).
- Enfoque en plantas ornamentales
 - Este dataset abarca una amplia variedad de géneros y especies, muchas de las cuales son utilizadas comúnmente como plantas ornamentales debido a sus características visuales atractivas, como flores vistosas, follaje decorativo o formas particulares.

Luego de hacer este análisis con las imágenes obtenidas de esta fuente, se concluye que no son aptas para el desarrollo del modelo de aprendizaje automático y se decide continuar revisando las otras fuentes disponibles.

2. Conjunto de datos de la competencia *Cassava Leaf Disease Classification* en Kaggle

El conjunto de datos de la competencia *Cassava Leaf Disease Classification* en Kaggle está diseñado para abordar el problema de clasificación de enfermedades en hojas de yuca. Este conjunto incluye 21,397 imágenes etiquetadas, cada una perteneciente a una de cinco categorías de estado de salud de la planta de yuca: Cassava Bacterial Blight (CBB), Cassava Brown Streak Disease (CBSD), Cassava Green Mottle (CGM), Cassava Mosaic Disease (CMD), y Healthy (hoja sana). Las imágenes están acompañadas por un archivo ‘.csv’ que asocia cada archivo de imagen con su etiqueta correspondiente, facilitando el entrenamiento y evaluación de modelos de aprendizaje automático.

Las imágenes fueron recolectadas durante encuestas regulares en Uganda y fueron *crowdsourced*, es decir, capturadas por agricultores locales utilizando cámaras móviles en sus jardines. Las etiquetas fueron asignadas por expertos del National Crops Resources Research Institute (NaCRRI) en colaboración con el laboratorio de inteligencia artificial de la Universidad Makerere en Kampala. Este enfoque colaborativo asegura que las etiquetas sean precisas y confiables, lo cual es crucial para el desarrollo de modelos de clasificación efectivos.

El conjunto de datos presenta algunos desafíos: una de las características más destacadas es la calidad variable de las imágenes. Debido al uso de cámaras móviles, unas cuantas imágenes tienen fondos inconsistentes, ruido en las etiquetas y calidad desigual. Además, las clases están desbalanceadas; las categorías CMD¹¹ y CBS¹² representan el 72% del total de imágenes.

Durante los dos trabajos de campo se identificó que en algunas huertas ya existe esta especie y que la comunidad tiene previsto incorporarla en otras huertas en los próximos meses. En este sentido, se consideró pertinente incluir esta especie en la prueba de concepto.

3. Datos PlantVillage

El conjunto de datos PlantVillage es una extensa colección de imágenes de hojas de plantas, diseñada para la identificación de enfermedades y el análisis de la salud de las plantas mediante técnicas de visión artificial y aprendizaje automático. Este conjunto incluye imágenes de hojas de plantas tanto sanas como enfermas, abarcando una amplia gama de especies y enfermedades. Las imágenes están disponibles en diferentes versiones: ‘color’ (RGB originales), ‘grayscale’ (en escala de grises) y ‘segmented’ (RGB con la hoja segmentada y corregida en color).

El conjunto de datos fue creado por Sharada P. Mohanty, David P. Hughes y Marcel Salathé, y las imágenes fueron recopiladas de diversas fuentes y estandarizadas para su uso en investigación y desarrollo. PlantVillage es un proyecto de código abierto que busca democratizar el acceso a la tecnología para la agricultura, facilitando el desarrollo de soluciones innovadoras para mejorar la productividad y la salud de los cultivos.

El conjunto de datos PlantVillage incluye imágenes de hojas de 14 especies de cultivos, que son: manzana (Apple), arándano (Blueberry), cereza (Cherry), maíz (Corn), uva (Grape), naranja (Orange), durazno (Peach), pimentón (Bell Pepper), papa (Potato), frambuesa (Raspberry), soja (Soybean), calabaza (Squash), fresa (Strawberry) y tomate (Tomato). Además, 12 de estas especies incluyen imágenes tanto de hojas sanas como afectadas por enfermedades específicas, abarcando un total de 17 enfermedades fúngicas, 4 bacterianas, 2 causadas por mohos, 2 virales y 1 provocada por ácaros.

A partir del listado de especies disponibles en la base de datos, se realizó un cruce con las especies identificadas en los huertos de Terraza Verde. Si bien no fue posible utilizar la totalidad del conjunto, se encontraron cinco especies coincidentes que resultan pertinentes para el desarrollo de esta prueba de concepto: manzana (Apple), maíz (Corn), papa (Potato), fresa (Strawberry) y tomate (Tomato). Adicionalmente, la comunidad manifestó durante las

¹¹ CMD: Cassava Mosaic Disease - Virus del mosaico de la yuca.

¹² CBS: Cassava Brown Streak Disease - Enfermedad de la raya marrón de la yuca.

visitas en campo, su intención de incluir el cultivo de manzana en el futuro, por lo que se decidió incorporar también esta especie en el conjunto final de imágenes a utilizar.

4. Datos de PlantPAD

PlantPAD es un sitio web dedicado a proporcionar información detallada sobre enfermedades de plantas. Ofrece una exploración exhaustiva de diversas enfermedades comunes causadas por hongos, bacterias, virus y otros patógenos, incluyendo descripciones detalladas, sintomatología, rutas de transmisión, así como metodologías de prevención y tratamiento. También ofrece una extensa base de datos de fotos de enfermedades de plantas, que cubren las manifestaciones de varias enfermedades en diferentes plantas. Estas imágenes ayudan a los usuarios a comprender mejor las características de las diferentes enfermedades y a realizar diagnósticos preliminares.

Los datos de PlantPAD son una valiosa fuente de información para la detección de enfermedades en plantas, pero requieren una solicitud de acceso individual para su uso. Este conjunto de datos incluye más de 420,000 imágenes que cubren 40 especies diferentes de plantas, lo que lo convierte en un recurso extenso y diverso. Las especies representadas incluyen albahaca, calabaza, coliflor, fresa, frijol, papa, pepino, tomate, algodón, alstonia, arándano, arjuna, arroz, bael, café, caña de azúcar, cereza, chinarr, cítricos, durazno, frambuesa, girasol, granada, guayaba, jambolán, jatrofa, limón, lúpulo, maíz, mango, manzana, naranja, okra, pimienta, plátano, pongamia, soya, té, trigo y uva. Esta diversidad de especies y la cantidad de imágenes disponibles permiten desarrollar modelos de aprendizaje automático robustos y precisos para el diagnóstico de enfermedades en plantas.

Al igual que con los datos de PlantVillage, se realizó un cruce entre las especies disponibles en PlantPAD y aquellas presentes en los huertos de Terraza Verde. Si bien se identificaron varias coincidencias, al inspeccionar las imágenes se observó que algunas especies solo estaban representadas en un único estado (saludable o enfermo), lo cual no se alinea con el objetivo de la prueba de concepto, que requiere ejemplos de ambas condiciones. Específicamente, especies como albahaca y calabaza fueron descartadas por esta razón. Finalmente, se seleccionaron las especies coliflor, pepino y frijol, mientras que, aunque la papa y el tomate también estaban disponibles en PlantPAD, se optó por utilizar las versiones provenientes de PlantVillage debido a su mayor similitud y consistencia visual.

3.3. Exploración y descripción de las características de datos seleccionados

Con base en el análisis realizado en Python sobre las imágenes seleccionadas, se llevó a cabo una exploración y descripción de las principales características de los datos. Inicialmente, se organizó la información en función del tipo de planta y su condición (saludable o enferma), lo que permitió identificar la distribución de clases y evaluar posibles desbalances. También se extrajeron estadísticas clave como el número total de imágenes por clase, su resolución promedio y dimensiones, evaluando el estado de homogeneidad de los datos antes de la fase de preprocesamiento que se llevó a cabo después. A continuación se muestra el análisis por cada una de las fuentes y datos seleccionados.

1. Conjunto de datos de la competencia Cassava Leaf Disease Classification en Kaggle

Dado que el conjunto de datos se compone exclusivamente de imágenes de yuca, se analizó un total de 21.397 imágenes. De estas, 18.820 (88%) corresponden a hojas enfermas y 2.577 (12%) a hojas sanas, lo que revela un marcado desequilibrio en la representación de ambas categorías.




Ilustración 4 - Distribución de Imágenes por Estado de Salud | Cassava Leaf Disease Classification Dataset

Ante el evidente desbalance en la representación de las imágenes de yuca según su estado de salud, se realizó un análisis detallado de la descomposición por enfermedades para comprender mejor la distribución de los datos (ver Ilustración 5). La marcada disparidad en la representación de las distintas enfermedades de la yuca dentro del conjunto de datos plantea desafíos para el desarrollo de modelos de clasificación automatizada. Si bien la alta prevalencia de imágenes de CMD podría facilitar su identificación, la escasez de ejemplos de otras enfermedades, como CBB, podría limitar la capacidad del modelo para reconocerlas con precisión, lo cual es importante tener en cuenta para mejoras de esta prueba de concepto.




Ilustración 5 - Distribución de Imágenes por Tipo de Enfermedad | Cassava Leaf Disease Classification Dataset

2. Datos PlantVillage

El conjunto de datos PlantVillage incluye un total de 28.903 imágenes correspondientes a distintas plantas (ver Tabla 6) según criterio de selección mostrado anteriormente. De estas, 29.897 (82.7%) representan hojas con algún tipo de enfermedad, mientras que solo 5.006 (17.3%) corresponden a hojas saludables. La marcada desigualdad evidencia un desbalance en la representación de clases, lo cual puede generar sesgos durante el entrenamiento del modelo, favoreciendo la predicción de clases de planta enfermas contra plantas saludables.

Tabla -6 - Distribución de Imágenes por tipo de planta | PlantVillage Dataset

Planta	Total de Imágenes	% de Imágenes sobre Total
Tomate	18160	63%
Maíz	3852	13%
Manzana	3174	11%
Papa	2152	7%
Fresa	1565	5%

Total	28903	100%
--------------	--------------	-------------




Ilustración 6 - Distribución de Imágenes por Estado de Salud | PlantVillage Dataset

3. Datos de PlantPAD

El conjunto de datos PlantPAD incluye un total de 2.643 imágenes correspondientes a distintas plantas (ver Tabla 7) según criterio de selección mostrado anteriormente. De estas, 1.668 (63.1%) representan hojas con algún tipo de enfermedad, mientras que solo 975 (36.9%) corresponden a hojas saludables. La marcada desigualdad evidencia un desbalance en la representación de clases, lo cual puede generar sesgos durante el entrenamiento del modelo, favoreciendo la predicción de clases de planta enfermas contra plantas saludables.

Tabla -7 - Distribución de Imágenes por tipo de planta | PlantPAD Dataset

Planta	Total de Imágenes	% de Imágenes sobre Total
Fríjol	1296	49%
Pepino Cohombro	691	26%
Coliflor	656	25%
Total	2643	100%




Ilustración 7 - Distribución de Imágenes por Estado de Salud | PlantPAD Dataset

3.4. Verificación de calidad de datos seleccionados

Para caracterizar la calidad y dimensiones de las imágenes por categoría, se desarrolló un script en Python que recorre todas las imágenes referenciadas en un archivo .csv, el cual contiene los nombres de archivo y sus respectivas clases. A partir de cada imagen, se extrajo el ancho y alto, lo que permitió calcular el número total de píxeles ($\text{ancho} \times \text{alto}$) por imagen. Estas dimensiones se usaron luego para

obtener el promedio de píxeles, el promedio de ancho y el promedio de alto por clase. Adicionalmente, se convirtió cada imagen a escala de grises para calcular su nivel de brillo promedio (media de los valores de intensidad) y se acumuló esta información para cada tipo de planta. A partir de los brillos promedio individuales se estimó la varianza del brillo por tipo de planta, como una medida de la variabilidad de iluminación entre las imágenes. Estas métricas permiten evaluar no solo el tamaño y resolución de las imágenes, sino también su consistencia en términos de iluminación, lo cual es clave para garantizar la calidad del dataset antes de entrenar modelos de aprendizaje automático.

Tabla -8 - Métricas de calidad imágenes seleccionadas

Dataset	Planta	Píxeles totales	Píxeles promedio	Ancho promedio	Alto promedio	Brillo promedio	Varianza brillo
Cassava (...) Dataset	Yuca	10270560000	4800000	8000	6000	1,16271E+16	3,6209E+16
PlantVillage Dataset	Fresa	102563840	655360	2560	2560	1,36276E+16	1,8027E+16
	Papa	141033472	655360	2560	2560	1,271E+16	2,1535E+15
	Maíz	252444672	655360	2560	2560	1,18901E+15	8,1991E+15
	Tomate	1190133760	655360	2560	2560	1,15584E+16	2,687E+16
	Manzana	207814656	655360	2560	2560	1,15653E+16	2,7705E+16
PlantPAD Dataset	Coliflor	6114267073	9,32053E+15	3,0084E+16	2,88865E+16	1,2084E+16	3,7584E+15
	Pepino	3411654400	4,93727E+15	2,18022E+15	2,08781E+16	1,22623E+16	4,5445E+15
	Cohombro						
	Fríjol	323750000	2500000	5000	5000	1,2364E+16	4,3544E+15

Los resultados obtenidos permiten identificar diferencias significativas en la calidad, tamaño y consistencia de las imágenes entre las distintas especies seleccionadas de los datasets analizados. Por ejemplo, las imágenes del dataset de *Cassava Leaf Disease Classification* presentan resoluciones mucho más altas (hasta 8000×6000 píxeles) y una alta varianza de brillo, lo que sugiere condiciones de captura diversas y mayor riqueza visual, aunque también un reto en términos de normalización. En contraste, las clases del dataset *PlantVillage* tienen imágenes uniformes en tamaño (2560×2560) y valores de brillo relativamente estables, lo que puede facilitar el entrenamiento de modelos, pero también implicar menor variabilidad contextual. Por otro lado, algunas imágenes de plantas del dataset *PlantPAD*, como Coliflor y Pepino, presentan métricas inconsistentes o anómalas —como tamaños y valores de píxeles excesivamente altos— que podrían deberse a errores de lectura o imágenes con metadatos inusuales, lo cual requiere revisión y posible depuración. En conjunto, estas métricas ofrecen una visión integral de la estructura del conjunto de datos, permitiendo detectar problemas de calidad, identificar posibles fuentes de sesgo y tomar decisiones informadas sobre preprocesamiento o selección de datos.

4. Preparación de los datos

Teniendo lista la exploración de los datos, y entendiendo el estado en el que se encuentran las imágenes, se procede a prepararlas con el objetivo de incluirlas en el modelo que se desarrolló en la siguiente fase de la prueba de concepto.

4.1. Integración y limpieza de múltiples fuentes de datos

Una vez concluido el proceso de revisión y análisis de las distintas fuentes, se decidió integrar las especies seleccionadas en un único conjunto de datos. Esta integración fue necesaria debido a que ninguna fuente individual ofrecía por sí sola la cobertura suficiente en términos de especies relevantes y estados fisiológicos requeridos para la prueba de concepto. Por tanto, se recurrió a la combinación de las múltiples bases ya explicadas —Cassava Leaf Classification, PlantVillage y PlantPAD—, seleccionando aquellas especies que se alineaban con el contexto actual y proyectado de los huertos de Terraza Verde. El resultado fue un conjunto de datos unificado, coherente y representativo, que constituye la base para el desarrollo de las siguientes fases del proyecto.

La siguiente tabla resume el proceso de revisión, evaluación y selección de datos realizado a partir de las diferentes fuentes consultadas. Cada una de las bases de datos fue analizada con base en la cantidad de especies disponibles, el número total de imágenes, y la representación de los distintos estados fisiológicos de las plantas (saludable o enfermo), aspectos clave para la construcción de un conjunto de datos robusto y alineado con los objetivos de la prueba de concepto.

Tabla -9 - Resumen exploración y selección de datos

Fuente	Pl@ntNet	Cassava Leaf Disease Classification	PlantVillage	PlantPAD
Total Especies disponibles	1.081	1	14	40
Total imágenes disponibles	306.146	21.397	54.303	421.163
Estados de las plantas disponibles	Saludable	Saludable Enfermo	Saludable Enfermo	Saludable Enfermo
Total Especies Seleccionadas	N/A	1	5	3
Especies Seleccionadas	N/A	Yuca	Fresa Manzana Maíz Papa Tomate	Coliflor Fríjol Pepino
Total imágenes seleccionadas	N/A	21.397	28.903	2.643
Estados de las plantas seleccionadas	N/A	Saludable Enfermo	Saludable Enfermo	Saludable Enfermo

Este proceso permitió consolidar un conjunto de datos con 9 especies y 52.943 imágenes, que combinan plantas actualmente presentes en los huertos con otras que se planean cultivar en el futuro, fortaleciendo así la aplicabilidad y escalabilidad del modelo que se trabajó. En las siguientes ilustraciones se puede ver como este dataset final queda y las distribuciones de imágenes de acuerdo al tipo de planta y estado de salud.




Ilustración 8 - Distribución de imágenes por tipo de plantas en conjunto de datos final




Ilustración 9 - Distribución de imágenes por estado de salud en conjunto de datos final




Ilustración 10 - Distribución de imágenes por tipo de planta y estado de salud en conjunto de datos final

4.2. Transformación de imágenes

Antes de alimentar estas imágenes al modelo, se realizaron un conjunto de transformaciones destinadas a mejorar la calidad del entrenamiento y permitir que el modelo generalice mejor a nuevas imágenes. Para que el lector pueda ver la variedad de fotos que se tiene en el conjunto de datos final se incluye la ilustración 11 con una muestra de seis fotografías.



Ilustración 11 - Muestra de imágenes originales del conjunto de datos final

4.2.1. División entre conjuntos de entrenamiento, validación y prueba

Primero, se separa una parte del dataset final como conjunto de prueba (*test*), que se usará exclusivamente al final del proceso para medir qué tan bien generaliza el modelo a datos completamente nuevos. Luego, del resto de los datos (no utilizados en prueba), se extrae un subconjunto para entrenamiento (*train*), con el cual el modelo aprende, y otro para validación (*validation*), que permite monitorear el rendimiento durante el entrenamiento y ajustar hiperparámetros sin afectar la evaluación final. Esta estructura evita el sobreajuste y garantiza una evaluación más realista y robusta del modelo. Para entender como quedan distribuidos los conjuntos de imágenes se presenta la siguiente ilustración.




Ilustración 12 - Distribución del conjunto de datos final en subconjuntos de entrenamiento, validación y prueba

4.2.2. Normalización de datos

Ahora bien, para los subconjuntos de entrenamiento y validación, se redimensionan todas las imágenes a un tamaño uniforme, lo cual es esencial para que el modelo pueda procesarlas fácilmente. Esta redimensión de imágenes a 128x128 píxeles (en el caso de arquitectura UNET) y 150x150 píxeles (en el caso de arquitecturas ResNet) se realizó principalmente para optimizar el procesamiento y la visualización, especialmente en aprendizaje automático. Al reducir el tamaño, se disminuye la carga computacional, permitiendo un procesamiento más rápido y eficiente. Además, estandariza las dimensiones de las imágenes, lo cual es crucial para muchos algoritmos.

Después de este proceso, los valores de los píxeles se normalizan escalándolos a un rango estándar entre 0 y 1, dividiendo por 255. Esta normalización mejora la estabilidad y velocidad del entrenamiento, ya que estandariza el rango de entrada de las imágenes. Sin ella, los gradientes durante el entrenamiento podrían volverse inestables, lo que ralentizaría el aprendizaje o impediría que el modelo aprenda de manera adecuada (Mohanty et al., 2016).

4.2.3. Transformaciones adicionales

Para el conjunto de entrenamiento, y entendiendo los requerimientos técnicos de arquitecturas como la ResNet, se aplican varias transformaciones a las imágenes con el objetivo de aumentar la diversidad del conjunto de datos y mejorar la capacidad del modelo para generalizar. Estas transformaciones incluyen rotaciones aleatorias de hasta 45 grados, acercamientos o alejamientos moderados (zoom), volteos tanto horizontales como verticales, desplazamientos aleatorios en altura y en anchura, así como un ligero recorte en ángulo (shear). Estas modificaciones se realizan de forma aleatoria en cada lote de imágenes, y las áreas vacías que puedan surgir se completan con el valor de píxel más cercano, evitando artefactos extraños en la imagen transformada.

En cambio, para el conjunto de prueba no se realizan transformaciones; las imágenes se cargan tal como están, únicamente redimensionándolas al tamaño objetivo requerido por el modelo. Esta decisión garantiza que las métricas de prueba reflejen el rendimiento del modelo frente a datos no alterados, proporcionando así una evaluación más realista y estable durante el entrenamiento.




Ilustración 13 - Ejemplo de aplicación de transformaciones

4.2.4. Balanceo de clases

Nuestro dataset presenta un claro desbalance en dos dimensiones críticas: en la distribución de plantas (donde ciertas especies como el tomate y la yuca están sobrerrepresentadas) y en la clasificación de salud de las plantas (con un predominio significativo de muestras enfermas frente a saludables). Este desequilibrio, documentado en la literatura como un factor limitante para el rendimiento de modelos CNN en clasificación multiclase (Buda et al., 2018), podría generar sesgos hacia las clases mayoritarias y reducir la capacidad predictiva para categorías minoritarias. Para mitigar este problema, se implementó un proceso de balanceo basado en las recomendaciones de la literatura académica: aplicación de oversampling (aumento de datos de las clases minoritarias durante el entrenamiento del modelo).

El proceso de oversampling realizado tiene como objetivo balancear el conjunto de datos de imágenes clasificadas por tipo de planta y estado de salud. Para cada clase, se verifica si la cantidad de imágenes supera un umbral específico. Si es así, se seleccionan aleatoriamente hasta ese límite. Si la cantidad es menor, se copian todas las imágenes originales y luego se generan imágenes aumentadas (mediante rotaciones, desplazamientos, zooms, etc.) hasta alcanzar el número objetivo por clase, y se guardan con un prefijo para diferenciarlas. Esto garantiza que cada clase tenga aproximadamente la misma cantidad de imágenes, lo que facilita un entrenamiento más equitativo de los modelos de aprendizaje automático.

Para asegurar un balance adecuado entre las clases de planta y estado, aplicamos oversampling hasta alcanzar 3,500 imágenes por categoría. Este umbral permitió formar un conjunto final de 63,000 imágenes, ligeramente superior al original, sin exceder la capacidad de cómputo y almacenamiento disponible. Al no establecer un límite superior más alto, aseguramos un rendimiento óptimo en el entrenamiento y la gestión de los datos.

Esto no solo equilibra la distribución de las categorías (planta-estado), sino que introduce variabilidad contextual en las imágenes, mejorando la generalización del clasificador y asegurando una representación más justa de todas las clases en el proceso de aprendizaje.

4.3. Vista Minable

Con todo el proceso anterior descrito, a continuación se presenta una muestra en imagen del archivo que compone la vista minable para este trabajo. La tabla cuenta con información detallada sobre las imágenes que están en el dataset final extraídas de los diferentes datasets (como PlantVillage, Cassava y PlantPAD). La vista es "minable" en el sentido de que cada fila representa una instancia que podría ser usada para tareas de análisis o entrenamiento de modelos de clasificación de enfermedades en plantas. A continuación se describen los campos principales de la tabla y sus valores:

Campos presentes:

- **Dataset:** Fuente del dato (PlantVillage, Cassava, PlantPAD).
- **Carpeta:** Ubicación de la imagen original.
- **Nombre del archivo:** Identificador único o nombre de archivo de la imagen.
- **Planta:** Nombre de la planta alimenticia en inglés (Apple, Potato, Cassava, Cauliflower, etc). Son 9 plantas alimenticias en total
- **Enfermedad inglés:** Nombre de la enfermedad que afecta la planta (por ejemplo, Cedar apple rust, Early blight, Bacterial Spot, etc.).
- **Saludable:** Indica que la planta esta saludable ("Si") o se encuentra enferma ("No")
- **Planta_Estado_ingles:** Combinación del nombre de la planta en inglés con el estado de la misma (enferma o saludable) en inglés. Como son 9 plantas alimenticias y 2 categorías de estados, este campo tiene 18 clases.
- **Planta español:** Nombre de la planta traducida al español.
- **Planta_Estado_Español:** Combinación del nombre de la planta en español con el estado de la misma (enferma o saludable) en español. Como son 9 plantas alimenticias y 2 categorías de estados, este campo tiene 18 clases.
- **Nombre traducido:** Nombre de la enfermedad traducido al español.
- **Nombre coloquial en Colombia:** Nombre de la enfermedad que se usa coloquialmente en Colombia.
- **Nombre coloquial en TV:** Nombre de la enfermedad que se usa coloquialmente en los grupos de huerteros asociados a Terraza Verde

Dataset	Carpeta	Nombre del archivo	Planta	Enfermedad Inglés	Saludable	Planta_Estado_Inglés	Planta Español	Planta_Estado_Español	Nombre traducido	Nombre Coloquial en Colombia	Nombre Coloquial en TV
Cassava Leaf Disease	Cassava	1000015157.jpg	Cassava	Cassava Bacterial Blight	No	Cassava_sick	Yuca	Yuca_Enferma	Bacteriosis de la yuca	Pudrición de la yuca	Podrida
Cassava Leaf Disease	Cassava	1000201771.jpg	Cassava	Cassava Mosaic Disease	No	Cassava_sick	Yuca	Yuca_Enferma	Enfermedad del mosaico de la yuca	Manchas amarillas en la yuca	Exceso de humedad
Cassava Leaf Disease	Cassava	100042118.jpg	Cassava	Cassava Brown Streak Disease	No	Cassava_sick	Yuca	Yuca_Enferma	Estria marrón de la yuca	Venas marrones de la yuca	Exceso de humedad
Cassava Leaf Disease	Cassava	1000723321.jpg	Cassava	Cassava Brown Streak Disease	No	Cassava_sick	Yuca	Yuca_Enferma	Estria marrón de la yuca	Venas marrones de la yuca	Exceso de humedad
Cassava Leaf Disease	Cassava	1000812911.jpg	Cassava	Cassava Mosaic Disease	No	Cassava_sick	Yuca	Yuca_Enferma	Enfermedad del mosaico de la yuca	Manchas amarillas en la yuca	Exceso de humedad
Cassava Leaf Disease	Cassava	1000837476.jpg	Cassava	Cassava Mosaic Disease	No	Cassava_sick	Yuca	Yuca_Enferma	Enfermedad del mosaico de la yuca	Manchas amarillas en la yuca	Exceso de humedad
Cassava Leaf Disease	Cassava	1000910826.jpg	Cassava	Cassava Green Mottle (CGM)	No	Cassava_sick	Yuca	Yuca_Enferma	Moteado verde de la yuca	Manchas verdes en la yuca	Manchas
Cassava Leaf Disease	Cassava	1001320321.jpg	Cassava	Cassava Bacterial Blight	No	Cassava_sick	Yuca	Yuca_Enferma	Bacteriosis de la yuca	Pudrición de la yuca	Podrida

Ilustración 14 - Muestra de algunas observaciones de la vista minable

4.4. Flujo de datos detallado

En continuidad con la representación general del flujo de datos presentada en la introducción, se avanza ahora hacia una versión más detallada y alineada con lo documentado en el presente trabajo. La imagen que se muestra a continuación ilustra con mayor claridad este flujo, con énfasis en las

fases 2 y 3 de la metodología CRISP-DM —comprensión y preparación de los datos—, las cuales han sido abordadas en profundidad en los dos últimos capítulos.




Ilustración 15 - Flujo de Datos (Comprensión y preparación de datos)
Fuente: Elaboración Propia

5. Modelado

5.1. Selección de modelos de clasificación de imágenes

A continuación se presenta la información recolectada, que sirve como base académica para la selección del modelo utilizado en la prueba de concepto. Esta información fundamenta la elección del modelo y el uso del conjunto de datos final generado.

5.1.1. Estado del Arte

El auge de los huertos urbanos ha generado una creciente necesidad de herramientas que faciliten la identificación de plantas y el manejo de cultivos en entornos domésticos y ciudadanos. Por esta razón, el desarrollo de aplicaciones de aprendizaje automático se presenta como una solución prometedora para abordar este desafío. Con esto en mente, el presente estado del arte explora diversas aplicaciones de inteligencia artificial, desde la detección de enfermedades en cultivos específicos hasta la identificación de múltiples especies en parcelas de vegetación, con el objetivo de identificar cuáles son los mejores modelos para utilizar en esta prueba de concepto y analizar la viabilidad y eficacia de estas tecnologías en el contexto particular de los huertos urbanos. Se revisaron estudios recientes y desafíos como PlantCLEF 2024, destacando la adaptabilidad y eficiencia de las redes neuronales convolucionales (CNN) en entornos con datos limitados o ruidosos (como es el caso particular de esta prueba de concepto).

Como primera referencia se encontró el trabajo de grado de Cristiano Muñoz¹³ (2023), en el cual el autor implementó una metodología de tres fases basada en CNN (VGG16, ResNet50, InceptionV4) para detectar enfermedades en plantas de papa. Los modelos alcanzaron precisiones superiores al 98% en escenarios reales. La estrategia incluyó el uso de mapas de calor para mejorar la detección en imágenes fragmentadas, lo cual es esencial cuando los recursos computacionales son limitados.

De otro lado, en el desafío PlantCLEF 2024 (Rounsevell et al., 2024), se exploró el uso de modelos Vision Transformer (ViT) preentrenados para identificar múltiples especies en imágenes de parcelas de vegetación. Aunque se alcanzaron precisiones Top-1 de 75.91% con modelos como ViTD2PC24All, el desempeño estuvo limitado por el cambio de dominio entre el conjunto de entrenamiento (plantas individuales) y el de prueba (imágenes multi-especie). Además, los modelos ViT enfrentan limitaciones inherentes, como su alta complejidad computacional y la necesidad de grandes cantidades de datos de entrenamiento, lo que requiere recursos significativos de GPU y puede ser una barrera para aquellos sin acceso a instalaciones de computación de alto rendimiento. Además, aunque los ViTs sobresalen con grandes conjuntos de datos, su rendimiento en conjuntos de datos más pequeños sin un pre-entrenamiento extenso puede ser inferior al de modelos más tradicionales como las CNNs.

En el estudio “AI-based Identification of Herbarium Specimens”(Goëau et al., 2021), se probó el uso de CNN combinadas con técnicas de adaptación de dominio para identificar especies a partir de especímenes de herbario digitalizados. A pesar de la diferencia visual entre imágenes de campo y de herbario, se lograron avances importantes con CNN clásicas y aprendizaje métrico, pero los modelos aún enfrentan desafíos significativos en términos de generalización. En contraste el documento “Detecting flowers on imagery with computer vision to improve continental scale grassland biodiversity surveying” (Elvekjaer et al., 2024) muestra un caso práctico en el que se utilizó Faster R-CNN (una variante de CNN) para detectar flores en imágenes de parcelas europeas. Aunque se lograron buenos resultados en detección, la clasificación de especies fue limitada por la calidad de

¹³ Clasificación de enfermedades en cultivos de papa empleando redes neuronales convolucionales.

imagen, lo que demuestra que las CNN pueden adaptarse a tareas de detección con restricciones reales, aunque el rendimiento depende de los datos disponibles.

Finalmente, estudios como “Pl@ntNet-300K” (Garcin et al., 2021) y “LifeCLEF 2021” (Joly et al., 2021) destacan la complejidad de identificar especies debido a la ambigüedad visual y el desbalance en los datos. A pesar de que los Transformers, como los ViT, ofrecen altos niveles de precisión y han demostrado resultados prometedores en desafíos como PlantCLEF 2024 (Rounsevell et al., 2024), su desempeño óptimo depende de grandes volúmenes de datos homogéneos, entrenamiento costoso y alta capacidad computacional. En contraste, las redes neuronales convolucionales (CNN) muestran una mayor adaptabilidad, facilidad de implementación en dispositivos móviles, mejor manejo de imágenes fragmentadas y menor requerimiento de datos etiquetados. Además, permiten estrategias por etapas como el uso de mapas de calor y aprendizaje por transferencia, lo que las hace más eficaces en entornos reales donde los datos pueden ser ruidosos, desbalanceados o escasos (Litvak et al., 2022).

En conclusión, las redes neuronales convolucionales (CNN) se consolidan como la mejor opción para esta prueba de concepto de identificación automática de imágenes de plantas en huertos urbanos. Su eficacia comprobada en estudios recientes, su capacidad para adaptarse a entornos con datos limitados o ruidosos, y su compatibilidad con técnicas como el aprendizaje por transferencia y el uso de mapas de calor, las posicionan como una solución robusta y accesible. A diferencia de los modelos basados en Transformers, que requieren altos recursos computacionales y grandes volúmenes de datos homogéneos, las CNN ofrecen un balance ideal entre precisión, eficiencia y viabilidad operativa, lo que las hace especialmente adecuadas para aplicaciones prácticas en contextos domésticos y ciudadanos.

Resumen del estado del arte¹⁴

A continuación se describen el estado del arte por cada una de las referencias consultadas:

Tabla -10 - Resumen Estado del Arte

Referencia / Año	Modelo utilizado	Tipo de datos	Métricas de evaluación	Conclusiones
Pl@ntNet-300K: a plant image dataset with high label ambiguity and a long-tailed distribution	CNNs varias (ResNet, DenseNet)	300K imágenes de plantas con anotaciones inciertas.	Precisión, capacidad de generalización	Pl@ntNet-300K es útil para estudiar incertidumbre en clasificación de especies, pero muestra desempeño inferior a ImageNet debido a datos desbalanceados. Se entrenaron múltiples arquitecturas de redes neuronales (ResNet, EfficientNet, Vision Transformer, entre otras) con cross-entropy loss. Se encontraron grandes diferencias en el rendimiento dependiendo del número de imágenes por clase, con una precisión significativamente menor en especies poco representadas. Además, el desempeño en Pl@ntNet-300K es mucho más bajo que en ImageNet, lo que resalta la dificultad del dataset.
Detecting Flowers in Imagery for Grassland Biodiversity	Faster R-CNN	Imágenes de pastizales europeos (LUCAS 2018)	Precisión (0.89), Recall (0.61)	La visión por computadora puede automatizar y mejorar el monitoreo de biodiversidad en pastizales, pero requiere imágenes de mayor calidad y modelos más especializados. La integración de estas técnicas en programas como LUCAS podría acelerar la recolección de datos y mejorar la toma de decisiones en conservación.
Beyond Supervision: Self-Supervised Learning in Plant Disease Recognition	Vision Transformer (CL-ViT)	Imágenes de enfermedades en plantas (PlantVillage + dataset real)	Comparación con modelos previos (FF-ViT)	Aprendizaje auto-supervisado mejora la identificación de enfermedades nunca antes vistas (zero-shot learning). Este estudio establece un nuevo punto de referencia en la identificación de enfermedades en plantas sin ejemplos previos, destacando el potencial del aprendizaje auto-supervisado en aplicaciones agrícolas y sistemas de reconocimiento de imágenes.
PlantCLEF 2024	Vision Transformers (ViT, DinoV2)	1.7M imágenes de plantas individuales + 1,695 imágenes de parcelas	F1-score (28.73%)	Incorporar auto-supervisión (SSL) para mejorar el aprendizaje con imágenes no etiquetadas. Crear conjuntos de datos con imágenes de parcelas anotadas para reducir la diferencia entre entrenamiento y prueba. Explorar técnicas de segmentación multi-escala para adaptarse a diferentes tamaños de plantas en una imagen. Este estudio refuerza la importancia de adaptar modelos de visión por computadora a escenarios del mundo real, donde los datos no siempre coinciden con los de entrenamiento.
PlantCLEF 2022	CNNs + ViTs	4M imágenes de 80K especies	MA-MRR (0.626)	ViTs superaron a CNNs en identificación global de plantas, pero requieren más recursos computacionales. Aunque ruidosos, los datos extraídos de la web ayudaron a mejorar la generalización de los modelos. Optimizar modelos para manejar la gran cantidad de clases sin aumentar demasiado el costo computacional. Ampliar la cobertura de datos en regiones tropicales con menos representación en los datasets actuales. Este trabajo marca un avance en la identificación automática de plantas a gran escala, demostrando el potencial de Vision Transformers y aprendizaje auto-supervisado en la clasificación de biodiversidad.
LifeCLEF 2021	CNNs, ViTs	Imágenes de herbarios, audio de aves, datos satelitales	Precisión por tarea (PlantCLEF: 20% MRR, BirdCLEF: 0.6932 F1-score)	ViTs emergen como alternativa a CNNs en biodiversidad; se necesitan mejores técnicas de aprendizaje auto-supervisado.

¹⁴ Esta información fue recopilada de artículos que se encuentran dentro de las Referencias.

Referencia / Año	Modelo utilizado	Tipo de datos	Métricas de evaluación	Conclusiones
AI-based Identification of Herbarium Specimens	CNNs con adaptación de dominio (GANs, métricas)	320K imágenes de herbarios + 3,186 fotos de campo	MRR (0.180 con regularización adversarial)	Las técnicas de aprendizaje profundo han mejorado significativamente la identificación de especies en imágenes, audio y datos ambientales. Los modelos Vision Transformers (ViTs) emergieron como una alternativa a las CNNs, aunque requieren más recursos computacionales. Los datos geográficos y de teledetección pueden mejorar la predicción de distribución de especies. Se identificaron desafíos en la identificación de especies en regiones tropicales, donde hay menos datos disponibles.
ML Using Digitized Herbarium Specimens for Phenology	Mask R-CNN	Imágenes de herbarios con anotaciones fenológicas	Precisión (96.3% en detección de estructuras)	El uso de ML en herbarios digitalizados facilita el análisis fenológico a gran escala, permitiendo un mejor monitoreo de la biodiversidad y los efectos del cambio climático. Aún quedan desafíos, como mejorar la calidad de los datos de entrenamiento y aplicar técnicas de aprendizaje auto-supervisado para optimizar la detección de patrones fenológicos.
Overview of LifeCLEF Plant Identification Task 2019: diving into Data Deficient Tropical Countries	Se probaron 26 modelos basados en CNNs, incluyendo Inception-ResNet, DenseNet y ResNet-50	Entrenamiento: 10,000 especies con 434,251 imágenes de la Enciclopedia de la Vida (EoL) y búsquedas web (Google, Bing). Prueba: 742 observaciones de campo identificadas por botánicos expertos.	El mejor modelo obtuvo 31.6% de precisión Top-1, muy por debajo del 67.5% logrado por expertos humanos. La diferencia del 36.5% en accuracy muestra que los modelos actuales aún no igualan la percepción humana en la identificación de especies tropicales	El estado del arte muestra que la identificación automática de plantas tropicales sigue siendo un reto abierto. A pesar de los avances en redes neuronales convolucionales y transformers, la falta de datos representativos y la alta biodiversidad dificultan la clasificación precisa. Se necesitan técnicas avanzadas para cerrar la brecha entre el rendimiento de modelos de deep learning y el de expertos botánicos
Clasificación de enfermedades en cultivos de papa empleando redes neuronales convolucionales Cristiano-Muñoz et al., 2023	VGG16, ResNet50, InceptionV4	760 imágenes de hojas de papa en campo, clasificadas en 5 categorías (enfermedades y sanas)	Precisión en prueba: ResNet50 (85.25%), InceptionV4 (99.67%)	La metodología de tres fases (transfer learning + mapas de calor) mejora significativamente la clasificación de enfermedades en cultivos de papa.

5.1.2. Modelo matemático¹⁵

A continuación, se presenta el modelo matemático que soporta las redes neuronales convolucionales (CNN), con el fin de comprender su funcionamiento y, a partir de ello, tomar decisiones más fundamentadas respecto a la selección de hiperparámetros.

Redes neuronales convolucionales

Dado una imagen de entrada X , una CNN transforma esa imagen paso a paso hasta obtener una predicción $y^\wedge$.

¹⁵ Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. <https://www.deeplearningbook.org/>

Los pasos incluyen:

Capa de Convolución

- Aplica filtros o kernels W sobre la imagen.
- Cada filtro extrae características relevantes.
- Se realiza mediante la operación de convolución:

$$Z = X * W + b$$

donde:

- X es la matriz de la imagen (o salida de la capa anterior),
- W es el kernel (matriz de pesos)
- b es el sesgo (bias),
- $*$ representa la convolución.

Función de Activación (ReLU):

- Se usa la función ReLU (Rectified Linear Unit) para introducir no linealidad:

$$A = \max(0, Z)$$

Esto elimina valores negativos y ayuda a la red a aprender patrones más complejos.

Capa de Pooling (Submuestreo):

- Reduce la dimensión de la imagen, conservando las características más importantes.
- Max-Pooling toma el valor máximo en una región de la imagen.

$$P_{i,j} = \max(A_{i:i+k,j:j+k})$$

donde k es el tamaño del filtro de pooling.

Capas Completamente Conectadas (Fully Connected - FC):

- Aplana la salida de las capas convolucionales en un vector.
- Aplica una combinación lineal con pesos W_{FC} :

donde P es la salida aplanada de la última capa de pooling.

$$y = W_{FC} \cdot P + b_{FC}$$

Función de Activación Softmax (Para Clasificación Multiclase):

- Convierte los valores de salida en probabilidades:

$$\hat{y}_i = \frac{e^{y_i}}{\sum_j e^{y_j}}$$

Esto asegura que la suma de todas las probabilidades sea 1.

Entrenamiento de la CNN

La red aprende ajustando los pesos W y sesgos b mediante descenso de gradiente y retropropagación:

- **Función de pérdida** (Ejemplo: Entropía Cruzada en clasificación):

donde y es la etiqueta verdadera, $\hat{y}$ es la predicción.

$$L = - \sum_i y_i \log(\hat{y}_i)$$

- Descenso de Gradiente (SGD, Adam, etc.):
 - Los pesos se actualizan en cada iteración con:

$$W := W - \eta \frac{\partial L}{\partial W}$$

donde η es la tasa de aprendizaje.

Flujo Completo en Predicción

Cuando la CNN recibe una nueva imagen en la fase de inferencia:

1. Extrae características con capas convolucionales.
2. Reduce la dimensionalidad con pooling.
3. Pasa a capas completamente conectadas para tomar decisiones.
4. Genera probabilidades con Softmax.

Predice la clase con la mayor probabilidad.

Transfer Learning

El aprendizaje por transferencia permite usar un modelo ya entrenado en un problema como base para resolver otro problema similar, reduciendo el tiempo y los recursos necesarios para el nuevo entrenamiento (Barrero, 2025). En el aprendizaje clásico supervisado, se asume que los datos de entrenamiento y prueba provienen de la misma distribución $P(X, Y)$ donde X son las entradas y Y las etiquetas. En el aprendizaje por transferencia, esto ya no se cumple (Ben-David et al., 2010).

Se trabaja con dos dominios:

- **Dominio origen (source domain):**
 $\mathcal{D}_S = \{\mathcal{X}_S, P_S(X)\}$
- **Dominio destino (target domain):**
 $\mathcal{D}_T = \{\mathcal{X}_T, P_T(X)\}$

Y dos tareas:

- **Tarea origen:**
 $\mathcal{T}_S = \{\mathcal{Y}_S, f_S(\cdot)\}$
- **Tarea destino:**
 $\mathcal{T}_T = \{\mathcal{Y}_T, f_T(\cdot)\}$

El objetivo del *transfer learning* es mejorar el aprendizaje de la función objetivo f_T en $\mathcal{D}_T$, utilizando el conocimiento contenido en $\mathcal{D}_S$ y $\mathcal{T}_S$, incluso cuando $\mathcal{D}_S \neq \mathcal{D}_T$ o $\mathcal{T}_S \neq \mathcal{T}_T$.

Desde el punto de vista de optimización, el *transfer learning* se puede entender como una forma de regularización donde el modelo se inicia en un punto de los parámetros θ que ya está cerca de un mínimo en la tarea destino, por lo que el proceso de fine-tuning busca una solución que esté en una región favorable del espacio de hipótesis.

Este enfoque ha sido explorado en redes neuronales profundas por (Yosinski et al., 2014), quienes demostraron que las capas inferiores (más cercanas a la entrada) aprenden representaciones más generales, mientras que las superiores son más específicas a la tarea.

Modelos utilizados en esta prueba de concepto

ResNet-50

Concepto de aprendizaje residual

En lugar de aprender directamente una función de mapeo $H(x)$, ResNet introduce bloques residuales que aprenden la función de diferencia $F(x) := H(x) - x$, de modo que la salida del bloque es

$$y = F(x, \{W_i\}) + x,$$

donde x es la entrada del bloque y $F(x, \{W_i\})$ se implementa mediante dos o tres capas convolucionales y funciones de activación σ . Este “atajo” o *skip connection* facilita la propagación del gradiente en redes profundas y combate la degradación del entrenamiento (vanishing/exploding gradients) (He et al., 2016).

Bloque “bottleneck” de ResNet-50

Para reducir el coste computacional, ResNet-50 utiliza bloques de tres capas en forma de “botella”:

- **Conv 1×1** para reducir dimensión de canales:

$$z_1 = \sigma(W_1 * x + b_1)$$

- **Conv 3×3** para procesamiento espacial:

$$z_2 = \sigma(W_2 * z_1 + b_2)$$

- **Conv 1×1** para restaurar dimensión de canales:

$$F(x) = W_3 * z_2 + b_3$$

- Finalmente, la salida del bloque es

$$y = F(x) + x.$$

Cada convolución va seguida de Batch Normalization y ReLU (He et al., 2016).

Arquitectura global de ResNet-50

Consta de:

- Capa inicial de Conv 3×3 y MaxPooling.
- Cuatro etapas (“stages”) con 3, 4, 6 y 3 bloques bottleneck, respectivamente.
- Global Average Pooling y capa totalmente conectada final con Softmax para clasificación.

Profundidad total: 50 capas de convolución parametrizadas (de ahí “ResNet-50”) (He et al., 2016).

U-Net

Arquitectura encoder-decoder con “skip connections”

- Camino de contracción (encoder):

Para cada nivel l , aplica dos convoluciones 3×3 con activación ReLU:

$$z_l^{(1)} = \sigma(W_l^{(1)} * z_{l-1} + b_l^{(1)}), \quad z_l^{(2)} = \sigma(W_l^{(2)} * z_l^{(1)} + b_l^{(2)}),$$

seguido de un MaxPooling 2×2 que reduce la resolución espacial $z_l = \text{Pool}(z_l^{(2)})$.

- Camino de expansión (decoder):

Cada nivel l realiza un *up-convolution* (transposed convolution) para duplicar la resolución:

$$u_l = \sigma(W_l^{\text{up}} \tilde{*} z_{l+1} + b_l^{\text{up}}),$$

donde $\tilde{*}$ es la convolución transpuesta. Luego concatena u_l con la salida correspondiente del encoder ($z_l^{(2)}$) y aplica dos convoluciones 3×3 con ReLU.

- Fusión por concatenación

Los “skip connections” transmiten $z_l^{(2)}$ directamente al decoder, preservando detalles espaciales finos:

$$c_l = \text{concat}(u_l, z_l^{(2)}),$$

seguido de convoluciones para refinar la segmentación.

- Capa de salida y función de pérdida

La última capa es una convolución 1×1 que proyecta a K clases:

$$\hat{y} = \text{Softmax}(W_{\text{out}} * z_0 + b_{\text{out}}).$$

Se suele entrenar con **Cross-Entropy** o **Dice Loss**, definidas como

$$\mathcal{L}_{CE} = - \sum_i y_i \log(\hat{y}_i), \quad \mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i y_i \hat{y}_i}{\sum_i y_i + \sum_i \hat{y}_i}.$$

U-Net destaca por su eficacia en tareas de segmentación con pocos datos y su capacidad de localización precisa gracias a los “skip connections” (Ronneberger et al., 2015).

5.1.3. Métricas de Evaluación

En el contexto de la identificación de plantas mediante redes neuronales convolucionales (CNNs), la precisión (accuracy) es una métrica crucial, especialmente cuando el objetivo principal es minimizar los falsos positivos. Esto significa evitar identificar incorrectamente una planta como perteneciente a una especie diferente. A continuación, se detallan las razones por las que la precisión es preferible a otras métricas en este escenario:

Importancia del Accuracy en la Identificación de Plantas

En la identificación de plantas, un falso positivo puede tener consecuencias significativas. Por ejemplo, en agricultura, identificar erróneamente una maleza como un cultivo puede llevar a la aplicación incorrecta de herbicidas, dañando el cultivo y generando pérdidas económicas. De manera similar, en la conservación, confundir una especie rara con una común podría resultar en la falta de protección o monitoreo adecuado.

La precisión se define como la proporción de predicciones correctas (tanto verdaderos positivos como verdaderos negativos) sobre el total de predicciones. Cuando nos enfocamos en reducir los falsos positivos, la precisión se convierte en una métrica clave por las siguientes razones:

- Minimiza las identificaciones erróneas: Una alta precisión implica que el modelo es muy bueno en identificar correctamente las instancias positivas (la planta es de la especie correcta) y las instancias negativas (la planta no es de esa especie). Al centrarse en los falsos positivos, la precisión nos ayuda a asegurar que, cuando el modelo clasifica una planta como una especie particular, es muy probable que esa clasificación sea correcta.
- Refleja la fiabilidad del modelo: Un modelo con alta precisión es más fiable para tomar decisiones en el mundo real. En el contexto de la identificación de plantas, esto se traduce en una mayor confianza en las recomendaciones o clasificaciones proporcionadas por el sistema.
- Equilibrio entre Verdaderos Positivos y Verdaderos Negativos: Aunque el enfoque esté en minimizar los falsos positivos, la precisión considera tanto los verdaderos positivos (identificaciones correctas de la especie objetivo) como los verdaderos negativos (identificaciones correctas de que una planta no es de la especie objetivo). Esto proporciona

una visión más completa del rendimiento del modelo en comparación con métricas que solo se centran en un aspecto.

Comparación con otras Métricas

Si bien otras métricas como la exhaustividad (recall), la puntuación F1 o la especificidad son importantes en diferentes contextos, la precisión se destaca cuando el énfasis está en la minimización de falsos positivos:

- **Exhaustividad (Recall):** Mide la proporción de verdaderos positivos que fueron identificados correctamente. Una alta exhaustividad es deseable cuando queremos asegurarnos de no perder ninguna instancia positiva (por ejemplo, detectar todas las plantas enfermas). Sin embargo, una alta exhaustividad puede venir a expensas de más falsos positivos. En el contexto de identificación de plantas, podríamos estar dispuestos a perder alguna detección (menor exhaustividad) si eso significa que las que sí detectamos son muy fiables (mayor precisión).
- **Puntuación F1:** Es la media armónica de la precisión y la exhaustividad. Es útil cuando se busca un equilibrio entre ambas. Si bien es una métrica robusta, no prioriza explícitamente la reducción de falsos positivos de la misma manera que la precisión.
- **Especificidad:** Mide la proporción de verdaderos negativos que fueron identificados correctamente. Una alta especificidad significa que el modelo es bueno para identificar cuando una planta no pertenece a una especie particular. Aunque está relacionada con la minimización de falsos positivos, la precisión ofrece una métrica más directa y global del rendimiento del modelo en este sentido.
- En resumen, cuando el principal riesgo radica en las consecuencias de una identificación incorrecta de una planta como una especie a la que no pertenece (falsos positivos), la precisión se convierte en la métrica de evaluación más relevante y preferible para optimizar el rendimiento de las CNNs

Dado que en estudios de referencia como LifeCLEF 2019 y Cristiano-Muñoz et al. (2023) se emplea el accuracy Top-1 como métrica estándar, y considerando además que el dataset está equilibrado y que el coste de confundir clases es simétrico, el accuracy no solo permite comparar de forma directa el desempeño global de distintos modelos, sino que además garantiza la confiabilidad de las identificaciones positivas y minimiza los falsos positivos algo crucial en aplicaciones donde las consecuencias de estos errores son significativas.

5.2. Construcción y Sintonización de modelos

Para abordar la construcción de los modelos, se implementó una estrategia en dos fases claramente diferenciadas, como se ilustra en la ilustración 16. En la Fase 1, se desarrollaron CNNs personalizadas desde cero, lo cual permitió un entendimiento profundo del comportamiento de los datos y de las dinámicas del aprendizaje en arquitecturas controladas, especialmente útil dada la disponibilidad limitada de recursos computacionales en las etapas iniciales. Este proceso incluyó iteraciones constantes de entrenamiento, evaluación y ajuste de hiperparámetros.

Una vez consolidada esta primera etapa y con acceso a recursos más robustos, se dio paso a la Fase 2, centrada en el uso de CNNs preentrenadas bajo un enfoque de aprendizaje por transferencia. Esta fase permitió acelerar el proceso de desarrollo y escalar el rendimiento del modelo mediante el congelamiento y posterior ajuste fino (fine-tuning) de capas específicas, adaptando modelos de última generación a las particularidades del conjunto de datos utilizado en la prueba de concepto.




Ilustración 16 - Diagrama de Fases de Construcción CNNs
Fuente: Elaboración propia

Fase 1 - CNNs personalizadas:

El proceso de desarrollo de las CNNs personalizadas involucra un ciclo iterativo de creación, entrenamiento y evaluación. Tras obtener una comprensión inicial del rendimiento del modelo, se procede a la optimización de hiperparámetros.

Fase 2 - CNNs Preentrenadas:

En el caso de las CNNs preentrenadas, se adoptó una estrategia de aprendizaje por transferencia. Inicialmente, se congelaron los pesos de las capas preentrenadas, excepto las últimas, que se adaptaron al conjunto de datos de esta prueba de concepto. Tras una evaluación inicial del rendimiento, se procede al ajuste fino (Fine-Tuning) de los pesos de las últimas capas. Este proceso permite adaptar el modelo preentrenado a las características específicas del nuevo conjunto de datos, mejorando su rendimiento. En este paso se realizaron modelos utilizando arquitecturas pre-entrenadas ResNet50 y U-Net.

Consideraciones para la Comparación:

Es importante destacar que, dada la naturaleza diferente de las CNNs personalizadas y preentrenadas, se decidió tomar medidas para garantizar la comparabilidad de los resultados. La optimización de hiperparámetros y el fine-tuning permitieron que ambos tipos de modelos alcanzaran su máximo potencial, lo que facilitó la evaluación comparativa de su rendimiento.

A continuación se presentan las arquitecturas propuestas para cada tipo de modelo de forma general:

Arquitectura de la CNN Personalizada:

```

Entrada: Imágenes (150x150x3)
|
V
[Conv2D (32 filtros, 3x3), ReLU] --> BatchNormalization --> MaxPooling2D (2x2)
|
V
[Conv2D (64 filtros, 3x3), ReLU] --> BatchNormalization --> MaxPooling2D (2x2)
|
V
[Conv2D (128 filtros, 3x3), ReLU] --> BatchNormalization --> MaxPooling2D (2x2)
|
V
[Conv2D (128 filtros, 3x3), ReLU] --> BatchNormalization --> MaxPooling2D (2x2)
|
V
Flatten()
|
V
[Dense (512 neuronas), ReLU] --> Dropout (0.5)
|
V

```

```
Dense (9 neuronas), Softmax
```

```
|
```

```
v
```

Salida: Probabilidades de 9 clases (En el caso de que sea clasificación de plantas) o de 18 clases (En el caso de que sea clasificación de plantas y estado de salud -*enferma* o *saludable*-)

1. **Capa de Entrada:**
 - o Las imágenes de entrada tienen una forma de (150, 150, 3), lo que significa que son imágenes de 150x150 píxeles con 3 canales de color (RGB).
2. **Capas Convolucionales y MaxPooling:**
 - o Cada capa convolucional extrae características de las imágenes mediante filtros.
 - o `Conv2D(32, (3,3), activation='relu')`: La primera capa convolucional utiliza 32 filtros de tamaño 3x3 y la función de activación ReLU.
 - o `BatchNormalization()`: Normaliza las salidas de la capa anterior, lo que ayuda a estabilizar el entrenamiento.
 - o `MaxPooling2D(2,2)`: Reduce la dimensionalidad espacial de las características, lo que disminuye la cantidad de parámetros y ayuda a prevenir el sobreajuste.
 - o Este patrón se repite con capas convolucionales adicionales, aumentando el número de filtros (64, 128, 128) para capturar características más complejas.
3. **Capa Flatten:**
 - o `Flatten()`: Convierte la salida de las capas convolucionales en un vector unidimensional, que se alimenta a las capas densas.
4. **Capas Densas (Fully Connected):**
 - o `Dense(512, activation='relu')`: Una capa densa con 512 neuronas y activación ReLU, que aprende combinaciones no lineales de las características extraídas.
 - o `Dropout(0.5)`: Aplica una tasa de dropout del 50%, lo que significa que durante el entrenamiento, el 50% de las neuronas se desactivan aleatoriamente para reducir el sobreajuste.
5. **Capa de Salida:**
 - o `Dense(9, activation='softmax')`: La capa final tiene 9 neuronas, una para cada clase de planta. La función de activación softmax produce una distribución de probabilidad sobre las 9 clases, lo que permite clasificar las imágenes en la clase más probable.

Puntos clave de esta arquitectura


- Esta arquitectura es común en problemas de clasificación de imágenes, ya que las CNN son muy efectivas para aprender características espaciales.
- El uso de `BatchNormalization` y `Dropout` ayuda a mejorar la estabilidad y la generalización del modelo.
- La función softmax es ideal para problemas de clasificación multiclase.

Arquitectura de la CNN Preentrenada:

ResNet (Redes Residuales) se establece como la arquitectura preentrenada de referencia en visión artificial según la literatura presentada anteriormente (Elvekjær et al., 2024) debido a que se destaca por resolver el problema de degradación en redes profundas mediante bloques residuales. Desarrollada en 2015 por Kaiming He, su diseño introduce conexiones de salto que permiten flujos de información directos entre capas, evitando la desaparición de gradientes al entrenar redes con cientos de capas. Matemáticamente, cada bloque residual aplica la función $y = F(x, \{W_i\}) + x$, donde F representa transformaciones no lineales

(convoluciones, normalización) y la entrada original. Esta estructura permite aprender ajustes residuales en lugar de mapeos completos, optimizando el entrenamiento.

Para esta prueba de concepto se utilizará la versión ResNet50 con una arquitectura (mostrada de manera simplificada) de la siguiente forma:



1. **Modelo ResNet Preentrenado:**
 - Se utilizará un modelo ResNet que ha sido entrenado en un gran conjunto de datos el cual es ImageNet.
 - Este modelo aprenderá a extraer características jerárquicas de las imágenes.
2. **Bloques Residuales Preentrenados (Capas Congeladas):**
 - Los bloques residuales, que forman la mayor parte de la red ResNet, se congelarán. Esto significa que sus pesos no se actualizarán durante el entrenamiento.
 - Las características generales aprendidas por estas capas se conservarán.
3. **Última Capa Densa (Capa Descongelada):**
 - La última capa densa del modelo preentrenado se reemplazará o se adaptará a la nueva tarea de clasificación.
 - Esta capa se "descongelará", lo que permite que sus pesos se ajusten al nuevo conjunto de datos.
 - Esta capa es la que se adaptará a las nuevas clases de imágenes.
4. **Capa de Salida (Adaptada a la Nueva Tarea):**
 - La capa de salida se modificará para que coincida con el número de clases en el conjunto de datos final de esta prueba de concepto.
 - Se utilizará una función de activación softmax para obtener una distribución de probabilidad sobre las clases.

Puntos clave de esta arquitectura

- El ajuste fino con ResNet permitirá aprovechar las características aprendidas previamente, lo que acelera el entrenamiento y mejora la precisión.
- Congelar las capas preentrenadas evita el sobreajuste en el nuevo conjunto de datos.
- Descongelar la última capa permitirá que el modelo se adapte a las características específicas del nuevo conjunto de datos.

U-Net se establece como la arquitectura de referencia en tareas de segmentación de imágenes en visión artificial según la literatura (Ronneberger et al., 2015), gracias a su encoder-decoder con “skip connections” que preservan información espacial fina y facilitan el entrenamiento de redes profundas. Matemáticamente, en cada nivel del encoder se aplican dos convoluciones 3x3 con activación ReLU

y pooling, mientras que en el decoder se realiza una convolución transpuesta para upsampling, se concatena con la salida correspondiente del encoder y se aplican dos convoluciones 3×3 con ReLU.

```

Entrada: Imágenes (150×150×3)
|
V
Encoder U-Net Preentrenado (capas congeladas)
|
V
[Bloques de Contracción (Encoder)]
|
V
[Bloques de Expansión (Decoder) — capas descongeladas]
|
V
Capa de Salida (Conv 1×1 adaptada a la tarea + softmax)
|
V
Salida: Máscaras de segmentación para n clases

```

1. **Encoder preentrenado (capas congeladas)**
 - Utiliza un backbone (e.g. ResNet34) ya entrenado en ImageNet.
 - Sus filtros generales se mantienen fijos para extraer características jerárquicas y evitar sobreajuste.
2. **Bloques de contracción (encoder)**
 - Cada nivel aplica dos convoluciones con activación ReLU.
 - Después reduce la resolución espacial mediante pooling, capturando patrones cada vez más globales.
3. **Bloques de expansión (decoder — capas descongeladas)**
 - Se aumenta la resolución con convoluciones transpuestas (upsampling).
 - Se fusiona (“skip connection”) con la salida correspondiente del encoder para recuperar detalles finos.
 - Se refina el resultado con dos convoluciones y activación ReLU.
4. **Capa de salida**
 - Convierte los mapas de características en n clases con una convolución 1×1.
 - Aplica softmax para obtener una probabilidad por píxel, generando la máscara final de segmentación.

Puntos clave de esta arquitectura

- Preentrenamiento del encoder acelera el entrenamiento y mejora la extracción de características generales.
- Congelar el encoder reduce el riesgo de sobreajuste en conjuntos de datos pequeños.
- Descongelar el decoder permite que el modelo aprenda a diferenciar específicamente los patrones de tu conjunto.
- Skip connections garantizan que la información de alta resolución fluya directamente, mejorando la precisión de los contornos segmentados.

5.2.1. Proceso de construcción del modelo.

A continuación se describe el proceso de construcción y sintonización del modelo teniendo como base el proceso de experimentación:

1. **Diseño y ajuste de un CNN “manual”**
 - Se parte de una arquitectura sencilla de varias capas (convolución, activación, pooling y dropout).

- Se experimenta con el número de épocas y el tamaño de lote.
- Se amplía progresivamente el número de clases y se aplica balanceo de datos por oversampling.

2. **Transfer learning con ResNet-50**

- Se incorpora aumento de datos (rotaciones, zoom, flips) en el preprocesamiento.
- Se prueban distintas estrategias de congelado de capas y fine-tuning de bloques finales.
- Se ajustan pesos de clase para mitigar desbalances.

3. **Cambio a U-Net**

- Se adopta un modelo totalmente convolucional con arquitectura encoder-decoder y concatenaciones skip-connections.
- Se utiliza early stopping para frenar el entrenamiento cuando la validación deja de mejorar.
- Se afinan parámetros como batch size y número de épocas.

Cada una de estas etapas añadió complejidad o refinamiento (desde un CNN básico, pasando por transfer learning, hasta un modelo especializado U-Net), permitiendo optimizar la capacidad de la red para la clasificación de especies y estados de las plantas, sin necesidad de introducir más cambios arquitectónicos drásticos en cada iteración.

6. Evaluación

A lo largo de la prueba de concepto se exploraron dos enfoques sucesivos: primero, una CNN personalizada; y luego un enfoque que se dividió en un esquema de transfer learning basado en ResNet-50; y un modelo especializado U-Net como se explicó en el capítulo anterior. A continuación se explicará el proceso de validación y evaluación de los modelos, el tablero de sintonización, definición de hiperparametros y el flujo de datos detallado de la evaluación.

6.1. Procesos de validación y evaluación de los modelos (entrenamiento y validación)

Una vez entrenados los modelos de clasificación de imágenes realizados (29 modelos) se llevó a cabo un proceso sistemático para validar su desempeño y evaluar su capacidad de generalización. Este proceso incluyó tanto el monitoreo durante el entrenamiento como el análisis posterior sobre los datos de prueba. A continuación, se describen los pasos seguidos:

6.1.1. Monitoreo del entrenamiento

- Se utilizaron gráficas de pérdida (loss) y Accuracy para las fases de entrenamiento y validación.
- Estas métricas permitieron observar cómo evolucionaba el aprendizaje del modelo a lo largo de las épocas, identificar posibles problemas como el sobreajuste, y asegurarse de que el modelo estuviera aprendiendo de manera efectiva.




Ilustración17 - Ejemplo gráficas de Accuracy y pérdida (loss). Esta gráfica corresponde al Modelo 29 Unet

El modelo muestra una rápida convergencia en las primeras 4 a 6 épocas, con curvas de entrenamiento y validación muy cercanas que evidencian buena generalización y ausencia de sobreajuste, y a partir de la época 8 a 10 las mejoras son mínimas.

6.1.2. Evaluación con matriz de confusión

- Para validar el desempeño del modelo en el conjunto de prueba, se generó una matriz de confusión multiclase (18 clases incluyendo 9 especies y su estado saludable o enferma).
- Esta herramienta permitió identificar qué clases eran clasificadas correctamente y cuáles generaban mayor confusión, proporcionando una visión detallada del comportamiento del modelo en cada categoría.




Ilustración 18 - Matriz de confusión. Esta gráfica corresponde al Modelo 29 (Versión conjunto de datos final – Balanceado- Unet)

La matriz de confusión normalizada pone de manifiesto que, para la gran mayoría de especies y sus estados —como coliflor, fresa, frijol, manzana, maíz, papa, pepino y tomate— el modelo acierta más del 90 % de las veces, con prácticamente cero confusiones entre “saludable” y “enfermo”. Sin embargo, la especie yuca presenta un rendimiento inferior con el 27 % de las hojas enfermas se reconocen correctamente y el 67 % de las saludables, evidenciando una confusión entre sus dos estados.

6.1.3. Análisis cualitativo de las predicciones

- Se realizó una revisión visual de predicciones, comparando etiquetas reales y etiquetas predichas.
- Este análisis cualitativo ayudó a comprender de manera visual lo que estaba prediciendo el modelo para datos no vistos:



Ilustración19 - Muestreo de predicciones vs etiquetas reales. Esto corresponde al Modelo 29 (Versión conjunto de datos final – Balanceado- Unet)

6.1.4. Evaluación mediante curvas ROC y valores AUC

El área bajo la curva (AUC) resume en un solo valor la capacidad del modelo para distinguir entre clases. Se calcularon curvas ROC por clase junto con sus respectivas áreas bajo la curva (AUC).

Las curvas ROC revelan una capacidad de discriminación casi perfecta para prácticamente todas las clases (AUC = 1.00), lo que indica que el modelo distingue con gran fiabilidad entre hojas sanas y enfermas de la mayoría de las especies, mientras que las clases de yuca presentan un leve descenso en el rendimiento (AUC = 0.99 para enfermas y 0.98 para sanas), señalando que ese par de categorías es algo más difícil de separar pero sigue mostrando una muy buena precisión.




Ilustración 20 – Gráfica de Curvas ROC por clase. Esta corresponde al Modelo 29 (Versión conjunto de datos final – Balanceado- Unet)

Este proceso integral permitió obtener una visión completa del rendimiento de los modelos, identificando fortalezas, debilidades y posibles oportunidades de mejora para las iteraciones realizadas.

Todos los modelos con sus resultados pueden ser consultados en el repositorio GitLab: <https://gitlab.com/CAOBA-Central/pruebas-concepto/puj-bogota/pruebas-concepto-g10/poc-094-puj-ia-servicio-comunidades-fase1>

6.2. Tablero de sintonización

El siguiente gráfico resume los experimentos realizados para la sintonización de hiperparámetros en modelos de redes neuronales convolucionales (CNN), diseñados para tareas de clasificación de imágenes de plantas. El gráfico de “Resultados de experimentación” que se explica a continuación emplea tres líneas codificadas por color para comparar el desempeño de cada modelo a lo largo de 29 iteraciones:

- Azul continuo: muestra el accuracy obtenido sobre el conjunto de entrenamiento.
- Naranja punteada: indica el accuracy en el conjunto de validación.
- Verde: refleja el accuracy en el conjunto de prueba.

Debajo del gráfico, una tabla correlaciona cada modelo (identificado por su versión del 1 al 29) con el número de categorías predichas, la arquitectura utilizada (manual, ResNet-50 o U-Net) y los valores precisos de accuracy en cada uno de los tres conjuntos de datos (entrenamiento, validación y prueba). Esta disposición permite ver de un vistazo cómo evolucionan el sobreajuste y la capacidad de generalización a medida que cambia la complejidad del modelo y del problema (más clases o arquitecturas más sofisticadas), destacando al modelo 29 como el de mejor balance entre entrenamiento, validación y prueba.

El número de clases varía en función de dos factores principales:

- La disponibilidad de datos por clase, lo cual condiciona la capacidad del modelo para aprender correctamente.
- La complejidad del objetivo de clasificación:
 - Con 9 clases, se busca únicamente identificar la especie de planta.
 - Con 18 clases, se clasifica la especie de planta considerando si está sana o enferma.
 - Con 37 clases, se realiza una clasificación más detallada, identificando la especie de la planta, su estado (sano o enfermo) y, en caso de enfermedad, la patología específica.

Adicionalmente, en algunos modelos se trabajó con 5 o 14 clases, correspondientes a versiones preliminares desarrolladas antes de abril, cuando aún no se contaba con el dataset completo. En esos casos:

- Las 5 clases corresponden a una clasificación simple de las 5 variedades de yuca.
- Las 14 clases se basan en los datos disponibles del conjunto PlantVillage.

Estas versiones iniciales se desarrollaron con el objetivo de avanzar en pruebas y ajustes arquitectónicos considerando la limitación de tiempo de esta prueba de concepto y los datos disponibles en ese momento.

Los resultados completos se pueden ver en el [Anexo 10.3](#) (Tablero de sintonización)




Ilustración 21 - Gráfico de resultados de experimentación

El análisis revela que, en la fase de CNN “manual” (modelos 1 al 6), aunque entrenamiento y validación alcanzaron valores elevados, el accuracy en prueba cayó drásticamente al crecer el número de clases, mostrando escasa generalización; los experimentos con ResNet-50 (modelos 10–20) fueron inestables y solo mejoraron tras ajustes de fine-tuning y pesos de clase, pero el modelo 27 superó los resultados anteriores al modificar los hiperparámetros del modelo inicial; finalmente, U-Net (modelos 21 al 26, 28 y 29) mantuvo curvas de entrenamiento y validación muy cercanas y un accuracy de prueba creciente, culminando en el modelo 29 como la configuración con el mejor equilibrio entre fit y generalización para la clasificación multicategoría de hojas.

6.3. Definición de Hiperparámetros

En una red neuronal convolucional (CNN), los hiperparámetros más importantes son aquellos que controlan la arquitectura y el proceso de aprendizaje del modelo. Entre ellos, destacan el número de filtros por capa, que define la capacidad de la red para extraer características (Goodfellow et al., 2016), y el tamaño del filtro (o kernel), que determina la resolución local de las características detectadas, siendo común el uso de tamaños 3×3 (Simonyan & Zisserman, 2014). Otro hiperparámetro fundamental es la función de activación, donde ReLU es la más utilizada por su simplicidad y efectividad (Nair & Hinton, 2010). También es crucial el tipo de pooling (e.g. MaxPooling2D), que reduce la dimensionalidad espacial conservando información relevante (LeCun et al., 1998).

En cuanto al proceso de entrenamiento, los hiperparámetros clave incluyen la tasa de aprendizaje, que afecta la velocidad y estabilidad del ajuste de pesos (Bengio, 2012), y el optimizador, siendo Adam una elección común por su eficiencia y adaptabilidad (Kingma & Ba, 2015). El batch size influye en la estabilidad del gradiente y el uso de memoria (Masters & Luschi, 2018), mientras que el número de épocas controla cuánto se expone el modelo a los datos. El uso de técnicas de regularización como Dropout ayuda a prevenir el sobreajuste (Srivastava et al., 2014). Finalmente, la función de pérdida

seleccionada (como categorical_crossentropy) debe alinearse con el tipo de problema, especialmente en clasificación multiclase (Géron, 2019).

A partir de la sintonización de los hiperparámetros a lo largo de las 29 iteraciones, se pudieron extraer las siguientes conclusiones: en la fase inicial (Modelos 1–12, CNN manual), el balanceo de datos mejora ligeramente la validación (por ejemplo, Modelo 1 balanceado: 90 % vs. 89 % sin balance, con pérdida 0,31 vs. 0,43), aunque su capacidad de generalización se ve limitada al aumentar las clases; el Modelo 2 destaca por su eficiencia global, alcanzando 93 % de accuracy en entrenamiento y validación con pérdidas reducidas (0,21/0,31); del mismo modo, el Modelo 6, con más épocas y batch size mayor, logra 91 % de validación y pérdida 0,30, confirmando el impacto positivo de estos ajustes. En la etapa de transfer learning (Modelos 13–18, ResNet-50), los ajustes de fine-tuning y pesos de clase corrigen la inestabilidad inicial y elevan la generalización, aunque sin superar los picos de la fase manual. Finalmente, con U-Net (Modelos 19 al 26, 28 y 29) se obtiene la mejor combinación de fit y generalización: las curvas de entrenamiento y validación permanecen muy cercanas y el accuracy de prueba crece de forma sostenida hasta el Modelo 29, que se posiciona como el óptimo para la clasificación multicategoría de hojas.

6.4. Flujo de datos detallado

En continuidad con la representación general del flujo de datos presentada en la introducción, se avanza ahora hacia una versión más detallada y alineada con lo documentado en el presente trabajo. La imagen que se muestra a continuación, la cual es una extensión del flujo mostrado en el [capítulo 4.4](#), ilustra con mayor claridad el trabajo que se ha realizado, con la adición de las fases 5 y 6 de la metodología CRISP-DM — Modelado y Evaluación —, las cuales han sido abordadas en los dos últimos capítulos.




Ilustración 22 - Flujo de datos detallado (Comprensión, preparación de datos, modelado y evaluación)
Fuente: Elaboración Propia

6.5. Definición del mejor modelo

El modelo 29 (CNN con arquitectura UNET, con datos balanceados y clasificando 18 clases) se destaca como el más equilibrado y robusto de todos los modelos evaluados por varias razones clave:

- Balance entre las tres métricas clave
 - A diferencia de otros modelos que muestran altos niveles de accuracy en entrenamiento pero una caída pronunciada en validación o prueba (indicando sobreajuste), el modelo 29 mantiene un rendimiento consistente y alto en los tres conjuntos:

- Training Accuracy: alto, lo que indica una buena capacidad de aprendizaje del patrón en los datos.
- Validation Accuracy: muy cercano al entrenamiento, lo que demuestra buena capacidad de generalización durante el ajuste.
- Test Accuracy: también elevado, validando que el modelo se comporta bien con datos completamente nuevos y no vistos.
- Uso de arquitectura U-Net adaptada para clasificación
 - Este modelo aprovecha la arquitectura U-Net, originalmente diseñada para segmentación, pero modificada exitosamente para tareas de clasificación. U-Net resulta especialmente útil para capturar características espaciales detalladas, lo que en este caso mejora la discriminación entre especies, estados y enfermedades en las imágenes de plantas.
- Complejidad del problema: 18 clases
 - El modelo 29 logra clasificar imágenes en 18 categorías, considerando especie y estado manteniendo una alta precisión, lo que refleja una gran capacidad de aprendizaje y generalización frente a una granularidad significativa del problema.
- Entrenado con el dataset completo y balanceado
 - Este modelo fue desarrollado una vez se tuvo acceso al dataset completo, permitiendo una representación más equitativa de todas las clases. Además, se aplicaron estrategias de balanceo de clases y data augmentation, lo que fortaleció la robustez del modelo frente a clases minoritarias.

7. Despliegue

Una vez validado el modelo, se realizó la entrega formal de dos componentes esenciales para su integración en la app: (1) la documentación técnica y (2) un archivo con el modelo entrenado y su función de inferencia. La documentación incluye una descripción general del modelo, las características de los datos utilizados, el preprocesamiento aplicado, la arquitectura seleccionada, los resultados de validación y las instrucciones para su uso dentro del entorno de la aplicación “Residuos ConCiencia”. El archivo entregable contiene el modelo entrenado en formato compatible (.h5), así como una función diseñada para recibir imágenes nuevas y devolver la clasificación correspondiente. Ambos elementos fueron entregados a Néstor Armando Nova Arévalo, PhD, Juan Erasmo Gómez Morantes, PhD y los demás miembros designados del equipo técnico, asegurando que cuenten con la información y los recursos necesarios para continuar con el proceso de integración de manera autónoma.

7.1. Prueba en campo

El 17 de mayo de 2025 se llevó a cabo un taller comunitario en la huerta del Parque Ecológico Cantarrana, en la localidad de Usme, con el objetivo de fortalecer las capacidades de los huerteros en el uso de inteligencia artificial aplicada al diagnóstico de hojas. La actividad fue organizada por la Pontificia Universidad Javeriana en colaboración con la Empresa de Acueducto de Bogotá (EAAB) y contó con la participación activa de huerteros locales, quienes recibieron una capacitación introductoria sobre IA, sus aplicaciones en la vida cotidiana y su implementación mediante modelos de redes neuronales para el reconocimiento de imágenes.

Durante la jornada, se explicó el funcionamiento técnico de la aplicación móvil “Residuos ConCiencia” y se realizó una sesión práctica en campo donde los asistentes utilizaron la app para diagnosticar el estado de salud de las plantas en tiempo real. También se aplicó una evaluación basada en el Modelo de Aceptación Tecnológica (TAM) para recoger retroalimentación sobre la experiencia. El taller finalizó con un espacio pedagógico liderado por la EAAB que abordó temas ambientales y saberes ancestrales, y promovió el uso de los recursos comunitarios disponibles en el parque. La actividad resultó en una apropiación efectiva de los conceptos básicos de IA, un manejo autónomo de la herramienta tecnológica y un intercambio de conocimientos entre la comunidad y los actores académicos, entre ellos, las autoras de esta prueba de concepto.

La encuesta aplicada a los asistentes se basa en el modelo TAM3 (Technology Acceptance Model 3), que evalúa la aceptación de tecnologías por parte de los usuarios. Mide percepciones sobre la utilidad, facilidad de uso, disfrute, intención de uso y otros factores que influyen en la adopción de una herramienta digital. Los usuarios clasifican cada afirmación en una escala de 1 a 5, donde 1 significa “totalmente en desacuerdo” y 5 “totalmente de acuerdo”.

Los resultados del TAM aplicados a la app “Residuos ConCiencia” enfocada en la funcionalidad de clasificación de imágenes de plantas (la cual utiliza el modelo de clasificación generado en esta prueba de concepto) muestran una aceptación general positiva por parte de los huerteros, con un puntaje promedio de 3,9. Las mayores fortalezas se encuentran en la percepción de utilidad (4,0), las normas sociales e imagen asociada al uso de la app (4,0) y factores emocionales como el disfrute y la intención de uso (4,0), lo que sugiere que los usuarios valoran su funcionalidad y están motivados a utilizarla. Sin embargo, se identifica un área de mejora en la facilidad de uso percibida (3,2), lo que indica la necesidad de optimizar la interfaz o brindar mayor acompañamiento para facilitar la interacción. En conjunto, los resultados reflejan una herramienta bien valorada por los huerteros

asociados a Terraza Verde, y que puede potenciar aún más su adopción mejorando la experiencia de usuario. Los resultados de las categorías evaluadas se presentan en la siguiente tabla:

Tabla-11 - Resultados TAM Visita Cantarrana

Categorías Evaluadas	Categorías en Español	Descripción	Promedio de Clasificación
Objective Usability	Usabilidad objetiva	Qué tan eficiente y útil es la app para cumplir su función.	4,1
Percieved Ease of Use	Fácilidad de usar percibida	Qué tan fácil se siente usar la app.	3,2
Subjective Norm	Norma sociales	Qué tanto influye la opinión de otras personas en el uso de la app.	4,0
Image	Imagen	Si usar la app mejora la imagen o reputación del usuario.	4,0
Job Relevance	Relevancia laboral	Qué tan útil es la app para las tareas o actividades del usuario.	4,1
Output Quality	Calidad del resultado	Qué tan buenos y precisos son los resultados que da la app.	4,0
Result Demonstrability	Demostrabilidad de resultados	Qué tan claro y visible es el beneficio de usar la app.	3,7
Computer Self-Efficacy	Autoeficacia informática	Qué tanta confianza tiene el usuario en su habilidad para usar tecnología.	3,8
Perception of External Control	Percepción de control externo	Si el usuario siente que tiene apoyo o recursos para usar la app.	3,6
Computer Playfulness	Diversión informática	Si usar la app se siente como algo entretenido o divertido.	4,0
Computer Anxiety	Ansiedad informática	Qué tan nervioso o incómodo se siente el usuario al usar tecnología.	3,9
Perceived Enjoyment	Disfrute percibido	Qué tanto disfruta el usuario usar la app.	4,0
Behavioral Intention	Intención conductual	Qué tantas ganas tiene el usuario de seguir usando la app en el futuro.	4,1
TOTAL TAM			3,9

A continuación, se presentan capturas de pantalla de la App "Residuos ConCienCIA" con el modelo de clasificación en funcionamiento, mostrando ejemplos reales de su uso para identificar el estado de salud de distintas especies de plantas alimenticias. Asimismo, se incluyen imágenes de los usuarios finales —los huerteros del programa Terraza Verde— utilizando la aplicación directamente en la huerta del Parque Ecológico Cantarrana. Estas evidencias visuales permiten ilustrar el impacto práctico del modelo en un entorno real, así como la apropiación comunitaria de la herramienta en actividades cotidianas de agricultura urbana.



Ilustración 23 - Huerteros utilizando la app "ConCienCIA" para clasificación de imágenes de planta en huertas urbanas




Ilustración 24 - Screenshots de la app "Residuos ConCienCIA" mostrando la prueba del modelo de clasificación de imágenes (modelo previo al modelo final seleccionado para despliegue)

7.2. Flujo de datos detallado

Con el fin de cerrar el flujo de datos detallado durante el documento, presentamos la última parte de este, la cual aborda el despliegue (Fase 7 de la metodología CRISP-DM) y que concluye el trabajo propuesto en esta prueba de concepto.




Ilustración 25 - Flujo de datos detallado y completado con las fases de CRISP-DM (comprensión y preparación de datos, modelado, evaluación y despliegue)

Fuente: Elaboración Propia

8. Conclusiones y Recomendaciones

El desarrollo de esta prueba de concepto ha demostrado la viabilidad técnica de utilizar modelos de aprendizaje profundo, específicamente redes neuronales convolucionales, para la clasificación de plantas y la detección de su estado de salud a partir de imágenes utilizando la metodología CRISP-DM, respondiendo así a la pregunta analítica. Esta prueba de concepto no solo valida la aplicabilidad de la inteligencia artificial en el ámbito de la agricultura urbana, sino que también contribuye significativamente al fortalecimiento de la gestión del conocimiento agrícola en comunidades urbanas. Al generar una herramienta con la cual se puede facilitar la identificación precisa de cultivos y la detección temprana de enfermedades en las plantas, se espera empoderar a los agricultores urbanos afiliados a las huertas de Terraza Verde con herramientas que optimizan sus prácticas y mejoran la salud de sus cultivos.

En relación con el primer objetivo específico, se logró no solo cumplir, sino superar ampliamente la meta inicial. Se propuso construir un conjunto de datos con al menos 5.000 imágenes representativas de cinco especies de plantas en dos condiciones (saludable y enferma), y tras un proceso riguroso de exploración de múltiples fuentes de datos de acceso abierto, se consolidó un dataset de más de 50.000 imágenes que abarcan nueve especies de plantas alimenticias diferentes. Este conjunto no solo garantiza diversidad y volumen, sino que además proporciona una base robusta para el entrenamiento de modelos con un alto potencial de generalización.

En cuanto al segundo objetivo, referido a la evaluación de al menos cuatro modelos de aprendizaje profundo, también se superó la meta, con el desarrollo y análisis de veintinueve (29) versiones de redes neuronales convolucionales. Estas versiones han sido evaluadas utilizando la métrica Accuracy para valorar su desempeño en términos de precisión y balance entre clases.

Referente al tercer objetivo específico, al concluir el presente trabajo, se cumplió satisfactoriamente con la entrega del modelo seleccionado, entrenado y documentado para su futura incorporación en la App "Residuos ConCiencia". El 24 de Mayo del 2025 se hizo entrega formal vía correo electrónico de la versión final del modelo, junto con el archivo '.h5' correspondiente para su carga, el índice de clases utilizado durante el entrenamiento, un instructivo detallado para su implementación y el formato de salida en '.json', diseñado para facilitar su integración directa en la aplicación. Con ello, se garantiza que el modelo puede ser reutilizado, actualizado y desplegado en el entorno de la app de manera eficiente.

Finalmente, con relación al cuarto objetivo de evaluar el modelo desarrollado con los usuarios finales, se logró validar su consistencia y coherencia con los requerimientos de las comunidades locales del programa Terraza Verde en la salida de campo del 17 de mayo de 2025. Esta evaluación se llevó a cabo a través de uso del TAM, como se explicó en el capítulo anterior y se generaron espacios de retroalimentación directa con los huerteros y actores comunitarios, quienes interactuaron con la herramienta y ofrecieron sus percepciones sobre su utilidad, facilidad de uso y pertinencia en el contexto local. Los resultados de esta validación confirmaron que el modelo responde adecuadamente a las necesidades del entorno, fortaleciendo así su aplicabilidad en escenarios reales de agricultura urbana y gestión de residuos orgánicos.

En síntesis, se logró desarrollar un modelo de clasificación de imágenes capaz de identificar 9 especies de plantas alimenticias, diferenciando cada una entre estados sanos y enfermos, lo que da como resultado un total de 18 categorías de predicción. Este modelo se basa en una arquitectura U-Net adaptada para tareas de clasificación, la cual no solo cumple con los requerimientos técnicos (accuracy en entrenamiento, validación y prueba) propios del análisis de datos, sino que también responde a las expectativas y necesidades expresadas por los usuarios finales. En el corto plazo, se

logró integrar exitosamente el modelo seleccionado en la aplicación "Residuos ConCienCIA", permitiendo que los huerteros lo utilicen directamente desde sus dispositivos. Esta implementación abre la puerta a un proceso continuo de retroalimentación, que permitirá mejorar la herramienta con base en su uso real en contextos comunitarios.

Sin embargo, para maximizar el impacto de esta prueba de concepto, es fundamental seguir optimizando el modelo de clasificación, ampliando el conjunto de datos de entrenamiento, realizando pruebas exhaustivas en entornos reales y desarrollando una interfaz de usuario intuitiva y fácil de usar. Para abordar el desbalanceo de clases, como en el caso de la yuca o el tomate, se recomienda explorar técnicas adicionales de aumento de datos (i.e.: Autoencoders Variacionales y Redes Generativas Adversarias) que no fueron computacionalmente viables en esta prueba de concepto debido a sus altos requerimientos de recursos.

Finalmente, es crucial abordar las consideraciones éticas relacionadas con el uso de la inteligencia artificial en la agricultura urbana, como la privacidad de los datos y el acceso equitativo a la tecnología, para garantizar que los beneficios de esta innovación se distribuyan de manera justa y sostenible en la comunidad. La colaboración con expertos en fitopatología y agrónomos podría enriquecer el conjunto de datos con información adicional sobre la severidad y las características visuales de cada enfermedad, mejorando así la robustez y la generalización del modelo, y asegurando que la herramienta sea precisa y útil para los agricultores urbanos de Terraza Verde y otras comunidades.

9. Referencias

- Acueducto y Alcantarillado de Bogotá. (2025). Parque Ecológico Cantarrana. https://www.acueducto.com.co/wpsportal/wps/portal/EAB2/gestores-ambientales/gestion-ambiental/parque_ecologico_cantarrana
- Arun, Y., & Viknesh, G. S. (2022). Leaf Classification for Plant Recognition Using EfficientNet Architecture. *Proceedings of IEEE 2022 4th International Conference on Advances in Electronics, Computers and Communications, ICAECC 2022*. <https://doi.org/10.1109/ICAIECC54045.2022.9716637>
- Barrero, N. (2025). Tareas típicas de visión artificial.
- Ben-David, S., Blitzer, J., Crammer, K., Kulesza, A., Pereira, F., & Vaughan, J. W. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175. <https://doi.org/10.1007/s10994-009-5152-4>
- Betancourt Rada, B. A. (2016). Bases Para La Reestructuración Del Programa De Agricultura Urbana Y Periurbana Agroecológica En Bogotá D.C., Con Base Los Lineamientos Dados En El Acuerdo 605 Del 27 De Agosto De 2015. <https://repository.udistrital.edu.co/server/api/core/bitstreams/deec61de-2c00-4e80-b85a-2c6f092bc2ca/content>
- Cantor Marín, K. M. (2010a). Agricultura urbana: elementos valorativos sobre su sostenibilidad. *Cuadernos De Desarrollo Rural*, 7(65), 61. <https://doi.org/https://doi.org/10.11144/Javeriana.cdr7-65.auev>
- Cantor Marín, K. M. (2010b). Agricultura urbana sostenibilidad y medios de vida experiencias en Ciudad Bolívar, Altos de Cazucá y Ciudadela Sucre. <https://doi.org/10.11144/JAVERIANA.10554.665>
- Chai, A. Y. H., Lee, S. H., Tay, F. S., Bonnet, P., & Joly, A. (2024). Beyond supervision: Harnessing self-supervised learning in unseen plant disease recognition. *Neurocomputing*, 610, 128608. <https://doi.org/10.1016/J.NEUCOM.2024.128608>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0. DaimlerChrysler.
- Acuerdo 605 de 2015 Concejo de Bogotá, D.C., (2015). <https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=62903>
- Elvekjaer, N., Martinez-Sanchez, L., Bonnet, P., Joly, A., Paracchini, M. L., & van der Velde, M. (2024). Detecting flowers on imagery with computer vision to improve continental scale grassland biodiversity surveying. *Ecological Solutions and Evidence*, 5(2). <https://doi.org/10.1002/2688-8319.12324>
- Garay Sarasti, H. (2019). Apropiación social por parte de grupos de interés para la conservación de los Cerros Orientales.". Secretaria Distrital de Ambiente. www.ambientebogota.gov.co
- Garcin, C., Joly, A., Lombardo, J.-C., Affouard, A., Chouet, M., & Servajean, M. (2021). Pl@ntNet-300K: a plant image dataset with high label ambiguity and a long-tailed distribution. Thirty-Fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2). <https://doi.org/https://doi.org/10.5281/zenodo.4726652>
- Goëau, H., Bonnet, P., & Joly, A. (2019). Overview of LifeCLEF Plant Identification Task 2019: diving into Data Deficient Tropical Countries. 2380(247). <https://hal.umontpellier.fr/hal-02283184>
- Goëau, H., Bonnet, P., & Joly, A. (2021). AI-based Identification of Plant Photographs from Herbarium Specimens. *Biodiversity Information Science and Standards*, 5, 1–4. <https://doi.org/10.3897/BISS.5.73751>
- Goëau, H., Bonnet, P., & Joly, A. (2022). Overview of PlantCLEF 2022: Image-based plant identification at global scale. 3180(153), 1916–1928. <https://hal-lirmm.ccsd.cnrs.fr/lirmm-03793591>
- Goodfellow, B. (2016). Deep Learning. <https://www.deeplearningbook.org/>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2016-December, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- IBM Corporation. (2021). Conceptos básicos de ayuda de CRISP-DM - Documentación de IBM. IBM Corporation. <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>
- Ideca: Infraestructura de Datos Espaciales para el Distrito Capital. (2022). Centro de Desarrollo Comunitario - CDC. Bogotá D.C. | Ideca. Unidad Administrativa Especial de Catastro Distrital. <https://www.ideca.gov.co/recursos/mapas/centro-de-desarrollo-comunitario-cdc-bogota-dc#>
- Instituto de ingeniería del conocimiento. (2025). La metodología CRISP-DM en ciencia de datos - IIC. Universidad Autónoma de Madrid. <https://www.iic.uam.es/innovacion/metodologia-crisp-dm-ciencia-de-datos/>

- Jardín Botánico de Bogotá. (2023, July 25). En Rafael Uribe Uribe se inaugura el tercer banco de semillas agroecológicas del Distrito - Jardín Botánico de Bogotá. Jardín Botánico de Bogotá. <https://jbb.gov.co/en-rafael-uribe-uribe-se-inaugura-el-tercer-banco-de-semillas-agroecologicas-del-distrito/>
- Jardín Botánico de Bogotá. (2025). Agricultura Urbana. Jardín Botánico de Bogotá. <https://jbb.gov.co/aplicacion-del-conocimiento/agricultura-urbana/>
- Joly, A., Goëau, H., Kahl, S., Picek, L., Lorieul, T., Cole, E., Deneu, B., Servajean, M., Durso, A., Bolon, I., Glotin, H., Planqué, R., de Castañeda, R. R., Vellinga, W. P., Klinck, H., Denton, T., Eggel, I., Bonnet, P., & Müller, H. (2021). Overview of LifeCLEF 2021: an evaluation of Machine-Learning based Species Identification and Species Distribution Prediction. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 12880, 371–393. https://doi.org/10.1007/978-3-030-85251-1_24
- Joly, A., Goëau, H., Kahl, S., Picek, L., Lorieul, T., Cole, E., Deneu, B., Servajean, M., Durso, A., Glotin, H., Planqué, R., Vellinga, W. P., Navine, A., Klinck, H., Denton, T., Eggel, I., Bonnet, P., Šulc, M., & Hruz, M. (2022). Overview of LifeCLEF 2022: An Evaluation of Machine-Learning Based Species Identification and Species Distribution Prediction. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 13390, 257–285. https://doi.org/10.1007/978-3-031-13643-6_19
- Landon-Lane, C. (2005). Los medios de vida crecen en los huertos. Folleto de La FAO Sobre Diversificación 2. <https://www.fao.org/4/y5112s/y5112s00.htm#Contents>
- Litvak, M., Divekar, S., & Rabaev, I. (2022). Urban Plants Classification Using Deep-Learning Methodology: A Case Study on a New Dataset. *Signals*, 3(3), 524–534. <https://doi.org/10.3390/SIGNALS3030031>
- López Usa, C. L. (2024). ARQUITECTURA PARA LA COMPARTICIÓN DE CONOCIMIENTOS SOBRE TRATAMIENTO Y TRANSFORMACIÓN DE RESIDUOS ORGÁNICOS EN UN ECOSISTEMA DE AGRICULTURA URBANA.
- Model download. (n.d.). Retrieved March 29, 2025, from https://plantpad.samlab.cn/model_down.html
- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7(September). <https://doi.org/10.3389/fpls.2016.01419>
- Muñoz, C. (2023). Clasificación de enfermedades en cultivos de papa empleando redes neuronales convolucionales. <https://repository.javeriana.edu.co/handle/10554/65257>
- Organización de las Naciones Unidas. (2025). 17 objetivos para transformar nuestro mundo. Objetivos de Desarrollo Sostenible. <https://www.un.org/sustainabledevelopment/es/>
- Pantoja Bohórquez, C. P., Martínez Grisales, K. J., Rincón Vivas, J. P., & Boada Arias, L. V. (2024). Mujeres y Agricultura Urbana Comunitaria: un estudio de caso múltiple en Bogotá, Colombia. *Convergencia*, 31(4). <https://doi.org/10.29101/CRCV.V31I0.22287>
- Pearson, K. D., Nelson, G., Aronson, M. F. J., Bonnet, P., Brenskelle, L., Davis, C. C., Denny, E. G., Ellwood, E. R., Goëau, H., Mason Heberling, J., Joly, A., Lorieul, T., Mazer, S. J., Meineke, E. K., Stucky, B. J., Sweeney, P., White, A. E., & Soltis, P. S. (2020). Machine Learning Using Digitized Herbarium Specimens to Advance Phenological Research. *Bioscience*, 70(7), 610–620. <https://doi.org/10.1093/BIOSCI/BIAA044>
- Ramírez, L. J. (2021, September 19). ¿Cuáles son las redes de agricultores y agricultoras de Bogotá? (foto) | Bogota.gov.co. Alcaldía de Bogota D.C. <https://bogota.gov.co/mi-ciudad/ambiente/cuales-son-las-redes-de-agricultores-y-agricultoras-de-bogota-foto>
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 9351, 234–241. https://doi.org/10.1007/978-3-319-24574-4_28
- Rounsevell, M. D. A., Loveland, P. J., Mayr, T. R., Armstrong, A. C., Rosa, D. de la, Legros, J.-P., Simota, C., & Sobczuk, H. (2024). Overview of PlantCLEF 2024: multi-species plant identification in vegetation plot images. *PlantCLEF 2024*, 3740(187), 1978–1988. <https://doi.org/10.13039/501100000780>
- Samlab. (n.d.). Image Downloads. Retrieved April 4, 2025, from https://plantpad.samlab.cn/image_down.html
- Secretaría de integración social. (2023). Diagnóstico local USME. chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://www.integracionsocial.gov.co/images/_docs/2024/Entidad/localidades/04062024-5-Usme-Diagnostico-2023.pdf
- Secretaría de Salud de Bogotá. (2024). Bien-Estar en Usme. <https://saludata.saludcapital.gov.co/osb/>

- Secretaría de Salud de Bogotá. (2048). Bien-Estar en Rafael Uribe Uribe. https://saludata.saludcapital.gov.co/osb/wp-content/uploads/2024/12/Rafael-Uribe_MasBienestar_2024_v1_2.pdf
- Secretaría de Salud de Bogotá, & Observatorio de Salud de Bogotá. (2025). Población de Bogotá D.C. 2005 - 2035 - SaluData - Observatorio de Salud de Bogotá. SaluData. <https://saludata.saludcapital.gov.co/osb/indicadores/poblacion-de-bogota-d-c-2005-2035/>
- Secretaría Distrital de Ambiente, & Observatorio Ambiental de Bogotá. (2022, May 22). Huertas Urbanas: ¿Qué son y cuántas hay en Bogotá? Observatorio Ambiental de Bogotá. <https://oab.ambientebogota.gov.co/huertas-urbanas-que-son-y-cuantas-hay-en-bogota/>
- Skat Foundation. (2021). Terraza Verde – Colombia | Skat Foundation. <https://skat-foundation.ch/terrazaverde-colombia/>
- Suache, J. (2022, December 29). Agricultura urbana y periurbana: Una alternativa para las bogotanas | Bogota.gov.co. Alcaldía de Bogotá D.C. <https://bogota.gov.co/mi-ciudad/ambiente/agricultura-urbana-y-periurbana-una-alternativa-para-las-bogotanas>
- Torres Vivas, D. M. (2018). Inclusión De La Agricultura Urbana Sostenible En Bogotá Dentro Del Posacuerdo Colombiano. Estudio De Caso: Ensayo De Producción Técnica De Lulo A Escala Urbana. <https://repository.udistrital.edu.co/server/api/core/bitstreams/5b37a41d-42ac-4b6e-891f-235b138c763e/content>
- Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., & Jégou, H. (2020). Training data-efficient image transformers & distillation through attention. <http://arxiv.org/abs/2012.12877>
- Transformers vs. Convolutional Neural Networks: What's the Difference? | Coursera. (n.d.). Retrieved April 4, 2025, from <https://www.coursera.org/articles/transformers-vs-convolutional-neural-networks>
- Vision Transformers vs CNNs at the Edge - Edge AI and Vision Alliance. (n.d.). Retrieved April 4, 2025, from https://www.edge-ai-vision.com/2024/03/vision-transformers-vs-cnns-at-the-edge/?utm_source=chatgpt.com
- Venkatesh, V., & Bala, H. (2008). Technology Acceptance Model 3 and a Research Agenda on Interventions. In The Author Journal compilation C (Vol. 39). Decision Sciences Institute.
- Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? <http://arxiv.org/abs/1411.1792>

10. Anexos

10.1. Visita a huertas urbanas

10.1.1. Primera visita Cedeco

A continuación se presentan algunas imágenes tomadas durante la visita al Centro de Desarrollo Comunitario Fe y Alegría – CEDECO.

Usuarios de la app “Residuos ConCiencia” en capacitación dictada por docentes de la Pontificia Universidad Javeriana sobre el uso de la app.



Visita al huerto ubicado en CEDECO.



Huerteros urbanos asociados a Terraza Verde usando la app “Residuos ConCiencia” para tomar y etiquetar fotos en el huerto ubicado en CEDECO.



10.1.2. Segunda visita parque ecológico Cantarrana

A continuación se presentan algunas imágenes tomadas durante la visita al Parque Ecológico Cantarrana.

Explicación de uso de inteligencia artificial en uso agrícola:



Uso de la aplicación en el huerto para prueba de clasificación y experiencia de usuario:



10.2. Diagrama Buyer persona

A continuación se presenta el Buyer persona de dos personas típicas de la comunidad de Terraza Verde:

Buyer persona




Ilustración 26 - Buyer Persona 1

Buyer persona



Ilustración 27 - Buyer Persona 2

10.3. Detalle tablero de resumen de sintonización de modelos y resultados

A continuación se presenta el detalle de los modelos realizados para la prueba de concepto donde se destaca el modelo 29 con el mejor Accuracy:

Tabla -12 - Detalle tablero sintonización modelos y resultados

No.	Nombre del Modelo	Tipo de Modelo	Búsqueda de Hiperparámetros	Data augmentation	Arquitectura	Batch es	Epochs	Tamaño filtro	Función de activación	Normalización	Pooling	Dropout	Mecanismos Auxiliares de control	Categorías a Predecir	Tipo de Predicción	Training Loss	Validation Loss	Training Accuracy	Validation Accuracy	Test Accuracy
1	Codigo_Yuca-5.ipynb	CNN	Manual	Rota las imágenes hasta 45 grados Aplica zoom aleatorio Invierte imágenes horizontal y verticalmente Rellena los píxeles vacíos tras transformaciones.	5 Capas	8	8	3x3	Relu	BatchNormalización	MaxPooling2D	0,5	Early Stopping	5	1 Yuca sana, 4 Yuca enferma	0,96	0,91	65%	66%	63,43%
2	Modelo 1.ipynb	CNN	Manual	Rota las imágenes hasta 45 grados Aplica zoom aleatorio Invierte imágenes horizontal y verticalmente Rellena los píxeles vacíos tras transformaciones.	5 Capas	8	8	3x3	Relu	BatchNormalización	MaxPooling2D	0,5	Early Stopping	9	9 especies de plantas	0,24	0,43	92%	90%	24,43%
3	Modelo 1-Balanceado.ipynb	CNN	Manual	Rota las imágenes hasta 45 grados Aplica zoom aleatorio Invierte imágenes horizontal y verticalmente Rellena los píxeles vacíos tras transformaciones.	5 Capas	8	8	3x3	Relu	BatchNormalización	MaxPooling2D	0,5	Early Stopping	9	9 especies de plantas	0,62	0,31	79%	89%	11,06%
4	Modelo 2.ipynb	CNN	Manual	Rota las imágenes hasta 45 grados Aplica zoom aleatorio Invierte imágenes horizontal y verticalmente Rellena los píxeles vacíos tras transformaciones.	5 Capas	8	10	3x3	Relu	BatchNormalización	MaxPooling2D	0,5	Early Stopping	9	9 especies de plantas	0,21	0,31	93%	93%	93,00%
5	Modelo 5.ipynb	CNN	Manual	Rota las imágenes hasta 45 grados Aplica zoom aleatorio Invierte imágenes horizontal y verticalmente Rellena los píxeles vacíos tras transformaciones.	5 Capas	8	8	3x3	Relu	BatchNormalización	MaxPooling2D	0,5	Early Stopping	14	14 (7 especies sanas, 7 especies enfermas)	0,39	0,91	88%	88%	65,20%
6	Modelo 6.ipynb	CNN	Manual	Rota las imágenes hasta 45 grados Aplica zoom aleatorio Invierte imágenes horizontal y verticalmente Rellena los píxeles vacíos tras transformaciones.	5 Capas	10	15	3x3	Relu	BatchNormalización	MaxPooling2D	0,5	Early Stopping	14	14 (7 especies sanas, 7 especies enfermas)	0,24	0,30	92%	91%	70,00%

No.	Nombre del Modelo	Tipo de Modelo	Búsqueda de Hiperparámetros	Data augmentation	Arquitectura	Batches	Epochs	Tamaño filtro	Función de activación	Normalización	Pooling	Dropout	Mecanismos Auxiliares de control	Categorías a Predecir	Tipo de Predicción	Training Loss	Validation Loss	Training Accuracy	Validation Accuracy	Test Accuracy
7	Modelo 9 - Datos Finales ResNet50.ipynb	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 preentrenada (pesos imagenet)	15	10	Según ResNet 50 3x3 7x7	Softmax	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	9	9 especies de plantas	0,0542	0,0451	93%	98%	17,49%
8	Modelo 9 - Datos Finales Balanceados ResNet50.ipynb	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 preentrenada (pesos imagenet)	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	9	9 especies de plantas	0,008	0,0373	100%	98%	15,57%
9	Modelo 10 - Datos Finales ResNet50.ipynb	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 preentrenada (pesos imagenet)	15	15	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	9	9 especies de plantas	0,0523	0,0295	98%	99%	17,42%
10	Modelo 10.1 - ResNet 50 Planta Estado	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 pre-entrenado (sin top) + GAP + Dense(num_classes, softmax)	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	18	9 especies de plantas mas estado (sana o enferma)	0,192	0,17	87%	94%	2,21%
11	Modelo 10.2 - ResNet 50 Planta Estado 3 Capas Unfreeze	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles	ResNet50 pre-entrenado (sin top) + GAP + Dense(num_classes, softmax) 3 capas descongeladas	15	20/5	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	18	9 especies de plantas mas estado (sana o enferma)	0,028	0,166	100%	94%	1,97%

No.	Nombre del Modelo	Tipo de Modelo	Búsqueda de Hiperparámetros	Data augmentation	Arquitectura	Batches	Epochs	Tamaño de filtro	Función de activación	Normalización	Pooling	Dropout	Mecanismos Auxiliares de control	Categorías a Predecir	Tipo de Predicción	Training Loss	Validation Loss	Training Accuracy	Validation Accuracy	Test Accuracy
				vacíos tras transformaciones con el vecino mas cercano.																
12	Modelo 10.3 - ResNet 50 Planta Estado Balanceado	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 pre-entrenado (sin top) + GAP + Dense(num_classes, softmax) 3 capas descongeladas	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclase) ReLU (capas internas)	BatchNormalización (heredada de ResNet)	Average	Ninguno	No aplica	18	9 especies de plantas mas estado (sana o enferma)	0,0796	0,0978	97%	96%	4,51%
13	Modelo 10.4 - ResNet 50 Planta Estado Balanceado- Unfreze	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 pre-entrenado (sin top) + GAP + Dense(num_classes, softmax) 3 capas descongeladas	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclase) ReLU (capas internas)	BatchNormalización (heredada de ResNet)	Average	Ninguno	No aplica	18	9 especies de plantas mas estado (sana o enferma)	0,08	0,096	97%	96%	4,46%
14	Modelo 11 - Datos Finales ResNet50.ipynb	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 preentrenada (pesos imagenet)	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclase) ReLU (capas internas)	BatchNormalización (heredada de ResNet)	Average	Ninguno	No aplica	37	9 Especies mas condición mas estado	0,5161	0,6149	67%	82%	2,63%
15	Modelo 12 - Datos Finales ResNet50 - Data Augmentation.ipynb	CNN	ResNet50	Brillo aleatorio (tf.image.random_brightness, max_delta=0.2) Contraste aleatorio (tf.image.random_contrast, 0.8-1.2) Ruido gaussiano (stddev=0.02)	ResNet50 pre-entrenado (include_top=False) + GlobalAveragePooling2D + Dense(num_classes, activation=softmax)	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclase) ReLU (capas internas)	BatchNormalización (heredada de ResNet)	Average	Ninguno	No aplica	37	9 Especies mas condición mas estado	3,03038	2,78463	13%	29%	1,30%
16	Modelo_12_ResNet50_Con_Mejora	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10%	ResNet50 preentrenada (pesos imagenet)	15	2	Según ResNet 50 3x3 7x7	Softmax (Multiclase) ReLU (capas internas)	BatchNormalización (heredada de ResNet)	Average	Ninguno	No aplica	37	9 Especies mas condición mas estado	3,74	3,649	0%	3%	1,51%

No.	Nombre del Modelo	Tipo de Modelo	Búsqueda de Hiperparámetros	Data augmentation	Arquitectura	Batches	Epochs	Tamaño filtro	Función de activación	Normalización	Pooling	Dropout	Mecanismos Auxiliares de control	Categorías a Predecir	Tipo de Predicción	Training Loss	Validation Loss	Training Accuracy	Validation Accuracy	Test Accuracy
				Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.																
17	Modelo 12 - Datos Finales ResNet50 Balanceados por Enfermedad y Data Augmentation	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 preentrenada (pesos imagenet)	15	2	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	37	9 Especies mas condición mas estado	3,695	3,597	0%	4%	3,02%
18	Modelo 13 - Datos Finales ResNet50 - Data Augmentation V2.ipynb	CNN	ResNet50	Brillo aleatorio (tf.image.random_brightness, max_delta=0.2) Contraste aleatorio (tf.image.random_contrast, 0.8-1.2) Ruido gaussiano (stddev=0.02)	ResNet50 pre-entrenado (include_top=False) + GlobalAveragePoolin g2D + Dense(num_classes, activation=softmax)	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	No aplica	37	9 Especies mas condición mas estado	3,030	2,785	13%	29%	0,44%
19	Modelo_14_ResNet50_class_weight	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 pre-entrenado (include_top=False) + GlobalAveragePoolin g2D + Dense(num_classes, activation=softmax)	15	20	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	Early Stopping	37	9 Especies mas condición mas estado	0,172	0,739	93%	78%	1,59%
20	Modelo_14_ResNet50_class_weight-unfreeze 2 layers add	CNN	ResNet50	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	ResNet50 pre-entrenado (include_top=False) + GlobalAveragePoolin g2D + Dense(num_classes, activation=softmax)	15	20/5	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	Early Stopping	37	9 Especies mas condición mas estado	0,246	0,634	93%	81%	1,53%
21	Modelo 2 – U-Net (Datos Finales).ipynb	CNN	Unet	rescale=1./255, validation_split=0.2	U-Net personalizado	32	5	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2 D (encoder) / UpSampling 2D (decoder)	Ninguno	No aplica	18	9 especies de plantas mas estado (sana o enferma)	0,7426	0,6921	76%	78%	78,00%

No.	Nombre del Modelo	Tipo de Modelo	Búsqueda de Hiperparámetros	Data augmentation	Arquitectura	Batch es	Epochs	Tamaño filtro	Función de activación	Normalización	Pooling	Dropout	Mecanismos Auxiliares de control	Categorías a Predecir	Tipo de Predicción	Training Loss	Validation Loss	Training Accuracy	Validation Accuracy	Test Accuracy
22	Modelo 15 - Unet_Planta_Estado_Balanceado	CNN	Unet	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	Unet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	10	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,23	0,218	91%	91%	0,28%
23	Modelo 15 - Unet_Planta_Estado	CNN	Unet	Rota las imágenes hasta 45 grados Aplica zoom hasta 20% Invierte imágenes horizontal y verticalmente Inclinación de hasta 10% Desplaza la imagen verticalmente y horizontalmente el 10% Rellena los píxeles vacíos tras transformaciones con el vecino mas cercano.	Unet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	10	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,282	0,305	90%	90%	3,48%
24	Modelo 16 - Unet_Planta_Estado Sin Data Augmentation	CNN	Unet	rescale=1./255, validation_split=0.2	Unet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	10	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,87	0,387	66%	87%	2,77%
25	Modelo 16 - Unet_Planta_Estado Balanceado Sin Data Augmentation	CNN	Unet	rescale=1./255, validation_split=0.2	Unet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	10	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,175	0,162	93%	93%	0,13%
26	Modelo 16 - Unet_Planta_Estado Balanceado Sin Data Augmentation 50%-Copy1	CNN	Unet	rescale=1./255, validation_split=0.2	Unet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	10	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,345	0,33	87%	88%	82,05%
27	Modelo 10.1 - ResNet 50 Planta Estado Sin Data Augmentation Param unet	CNN	ResNet50	rescale=1./255, validation_split=0.2	ResNet50 pre-entrenado (sin top) + GAP + Dense(num_classes, softmax)	32	20	Según ResNet 50 3x3 7x7	Softmax (Multiclas e) ReLU (capas internas)	BatchNormaliza tion (heredada de ResNet)	Average	Ninguno	EarlyStopping Reduce learning rate	18	9 especies de plantas mas estado (sana o enferma)	1,174	0,935	65%	72%	72,05%
28	Modelo 16 - Unet_Planta_Estado Sin Data Augmentation 100%	CNN	Unet	rescale=1./255, validation_split=0.2	Unet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	15	Conv2 D: 3x3; salida: 1x1	Softmax (Multiclas e) ReLU (capas internas)	Ninguna adicional	MaxPooling2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,267	0,273	91%	90%	91,63%

No.	Nombre del Modelo	Tipo de Modelo	Búsqueda de Hiperparámetros	Data augmentation	Arquitectura	Batches	Epochs	Tamaño filtro	Función de activación	Normalización	Pooling	Dropout	Mecanismos Auxiliares de control	Categorías a Predecir	Tipo de Predicción	Training Loss	Validation Loss	Training Accuracy	Validation Accuracy	Test Accuracy
29	Modelo 16 - Unet_Planta_Estado Balanceado Sin Data Augmentation 100%	CNN	Unet	rescale=1./255, validation_split=0.2	UNet simétrico (32→64→128→... + concatenaciones + GAP + Dense)	32	15	Conv2D: 3×3; salida: 1×1	Softmax (Multiclase) ReLU (capas internas)	Ninguna adicional	MaxPooling 2D (encoder) / UpSampling 2D (decoder)	Ninguno	EarlyStopping	18	9 especies de plantas mas estado (sana o enferma)	0,137	0,196	94%	92%	94,18%